

学校代码: 10286

分类号: TN47

密 级: 公开

U D C: 621.38

学 号: 163769



东南大学

工程硕士学位论文

基于 DNN 的高鲁棒性低功耗语音端点检测设计

(学位论文形式: 应用研究)

研究生姓名: 夏梦雯

导师姓名: 杨 军 教授

朱 敏 高工

申请学位类别	<u>工程硕士</u>	学位授予单位	<u>东南大学</u>
工程领域名称	<u>集成电路工程</u>	论文答辩日期	<u>2019 年 6 月 1 日</u>
研究方向	<u>数字集成电路设计</u>	学位授予日期	<u>2019 年 月 日</u>
答辩委员会主席	<u>李祖华</u>	评 阅 人	<u>李祖华 吴建辉</u>

2019 年 6 月 4 日

東南大學

工程硕士学位论文

基于 DNN 的高鲁棒性低功耗语音端点检测
设计

专业名称： 集成电路工程

研究生姓名： 夏梦雯

导师姓名： 杨军 教授

朱敏 高工

2019 年 6 月 4 日

HIGH ROBUST LOW POWER VOICE ACTIVITY DETECTION DESIGN BASED ON DNN

A Thesis Submitted to

Southeast University

For the Professional Degree of Master of Engineering

BY

Xia Mengwen

Supervised by

Professor YANG Jun

and

Senior Engineer ZHU Min

School of Microelectronics

Southeast University

June 2019

东南大学学位论文独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名：_____日期：_____

东南大学学位论文使用授权声明

东南大学、中国科学技术信息研究所、国家图书馆、《中国学术期刊（光盘版）》电子杂志社有限公司、万方数据电子出版社、北京万方数据股份有限公司有权保留本人所送交学位论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括以电子信息形式刊登）论文的全部内容或中、英文摘要等部分内容。论文的公布（包括以电子信息形式刊登）授权东南大学研究生院办理。

研究生签名：_____导师签名：_____日期：_____

摘要

近年来,越来越多的语音识别智能应用走入了大家的日常生活。语音端点检测 (Voice Activity Detection, VAD) 作为语音识别领域中必不可少的关键技术之一,其精确性和功耗在整个语音识别系统中起着十分重要的作用。从传统的 VAD 加速器所面临的非平稳噪声下精确度低、功耗大等问题出发,本文设计并实现了一种基于深度神经网络 (Deep Neural Network, DNN) 的高鲁棒性低功耗 VAD。

本文从 VAD 模型的算法特征出发,分别针对特征提取和语音分类做了算法优化和硬件实现。首先,优化了基于梅尔频率倒谱系数 (Mel Frequency Cepstrum Coefficient, MFCC) 的特征提取算法,并利用高鲁棒性 DNN 实现了快速傅里叶变换、离散余弦变换以及语音分类,提高了 VAD 在低信噪比和非平稳噪声下的性能,提高了语音和非语音命中率,实现了 VAD 的高鲁棒性;其次,引入数模混合近似计算,基于多阶量化共享乘法器实现 VAD 的动态精度可配运算,降低了运算复杂度和电路复杂度,实现了 VAD 的低功耗高能效。本文采用 TSMC28nm 工艺,VAD 布局布线后的面积为 0.52mm^2 ,工作频率为 1.6MHz,功耗约为 $6\sim 12\mu\text{W}$,能效可达 $33.33\sim 66.67\text{TOPS/W}$ 。

实验结果表明,本文通过优化 VAD 的算法和硬件实现,相比于 Price 等人的研究结果相比,精确度增长了 9%,能效提高至 Thinker 的 6.5 倍,改善了当前 VAD 面临的功耗高和精确度低的问题。本文对 VAD 设计提供了一种新的解决方案。

关键词: 语音端点检测, 深度神经网络, 特征提取, 语音分类, 梅尔频率倒谱系数, 近似计算

Abstract

In recent years, more and more voice recognition intelligent applications have entered everyone's daily life. Voice Activity Detection (VAD) is one of the key technologies in the field of speech recognition. Its accuracy and power consumption play an important role in the whole speech recognition system. Starting from the problems of low accuracy and high power consumption under the non-stationary noise faced by traditional VAD accelerators, this thesis designs and implements a high robust low power VAD based on Deep Neural Network (DNN).

Based on the algorithm characteristics of VAD, this thesis makes algorithm optimization and hardware implementation for feature extraction and speech classification. Firstly, the feature extraction algorithm based on Mel Frequency Cepstrum Coefficient (MFCC) is optimized, and fast fourier transform, discrete cosine transform and speech classification are realized by high robust DNN, which improves VAD performance in Low SNR and non-stationary noise and achieves high robustness of VAD. Secondly, the digital-analog hybrid approximation calculation is introduced, and the multi-order quantization shared multiplier is used to realize the dynamic precision configurable operation of VAD, which reduces the computational complexity and circuit complexity, and realizes the low power consumption and high energy efficiency of VAD. Based on the TSMC28nm, the system area of VAD is 0.52mm^2 , the working frequency is 1.6MHz, the power consumption is about $6\sim 12\mu\text{W}$, and the energy efficiency can reach $33.33\sim 66.67\text{TOPS/W}$.

The experimental results show that the proposed algorithm optimizes the VAD algorithm and hardware, compared with Price, the accuracy is increased by 9%, and the energy efficiency is about 6.5 times that of Thinker, which solves the bottleneck of consumption and precision faced by current VAD. This thesis provides a new solution for VAD design.

Keywords: Voice Activity Detection, Deep Neural Network, Feature extraction, Speech classification, Mel Frequency Cepstrum Coefficient, Approximate calculation

目录

摘要.....	I
Abstract	III
目录.....	V
第一章 绪论.....	1
1.1 课题背景与意义.....	1
1.1.1 课题背景.....	1
1.1.2 课题意义.....	3
1.2 国内外研究现状.....	4
1.2.1 VAD 的研究现状.....	4
1.2.2 基于 DNN 的 VAD 研究现状	5
1.3 研究内容与设计指标.....	5
1.3.1 研究内容.....	5
1.3.2 设计指标.....	6
1.4 论文组织.....	7
第二章 VAD 的算法分析与比较.....	9
2.1 特征提取的算法分析.....	9
2.1.1 主流的特征提取算法分析	10
2.1.2 基于 MFCC 的特征提取算法分析	12
2.2 语音分类的算法分析.....	16
2.2.1 主流的语音分类算法分析	17
2.2.2 基于 DNN 的语音分类算法分析	19
2.3 近似乘法算法分析与实现.....	21
2.3.1 截断乘法算法.....	21
2.3.2 对数乘法算法.....	21
2.3.3 共享乘法算法.....	23
2.3.4 近似乘法算法比较分析	23
2.4 本章小结.....	24
第三章 基于 DNN 的高鲁棒性低功耗 VAD 硬件设计	27
3.1 特征提取模块的优化设计	27
3.1.1 预加重模块设计	27
3.1.2 分帧模块设计	28
3.1.3 FFT 与 DCT 的设计	28
3.1.4 能量谱计算模块设计	29
3.2 DNN 加速器设计	31

3.2.1 DNN 加速器中的运算单元设计	32
3.2.2 多阶量化共享乘法器的设计	33
3.3 基于 DNN 的 VAD 系统结构	36
3.4 本章小结.....	37
第四章 基于 DNN 的高鲁棒性低功耗 VAD 系统调度和优化方案	39
4.1 基于 DNN 的 VAD 系统调度方案	39
4.2 DNN 加速器在 VAD 系统上的优化映射方案	40
4.2.1 基于数字方法实现的 DNN 加速器	41
4.2.2 基于数模混合近似计算的 DNN 加速器.....	42
4.3 基于 DNN 的 VAD 动态精度可配方案	47
4.4 本章小结.....	49
第五章 验证及结果分析.....	51
5.1 基于 DNN 的 VAD 功能验证	51
5.1.1 验证环境.....	51
5.1.2 验证结果及分析	51
5.2 基于 DNN 的 VAD 综合结果	56
5.3 与典型 VAD 的比较分析	58
5.4 本章小结.....	59
第六章 总结与展望.....	61
6.1 总结.....	61
6.2 展望.....	61
致谢.....	63
参考文献.....	65
攻读硕士学位期间发表的论文	71

第一章 绪论

1.1 课题背景与意义

1.1.1 课题背景

语音端点检测(Voice Activity Detection, VAD)又称语音活动检测, 语音边界检测, 是一种在语音处理中使用的技术。VAD 可以从声音信号流里识别和消除长时间的静音期, 从复杂的环境中区分语音和非语音部分, 检测语音的存在或不存在, 并判断出语音信号的始点和终点。VAD 作为语音系统的前端部分, 对语音编码、语音增强以及语音识别等应用都十分重要。在语音应用中使用 VAD 技术不但可以避免不必要编码, 还可以避免传输数据包, 从而节省了计算和网络带宽。VAD 最初用于时间分配语音差值 (Time-Assignment Speech Interpolation, TASI) 系统, 是基于各种语音应用的重要技术手段, 为了优化灵敏度、精确度, 计算成本和计算延时等性能参数, 国内外提出了各种优化 VAD 的方案。




图 1-1 VAD 的基本算法流程框图

如图 1-1 所示, 语音的特征提取和语音分类是 VAD 算法研究的核心。VAD 通过语音和噪声对于相同参数所表现的不同特征来区分语音和非语音。语音的预处理包括滤波, 采样, 预加重, 分帧和加窗等, 其中滤波采用带通滤波器, 采样频率由奈奎斯特采样定律给出, 即在语音最高频率的两倍以上, 保证还原完整的语音信息, 分帧处理使得各帧之间有交叠。特征提取是提取可以反映语音和噪声差别的特征参数。语音分类和端点检测, 用来区分语音和非语音帧。语音后处理单元对语音进行平滑滤波。

早期的 VAD 算法主要包括基于线性预测编码 (Linear Predictive Coding, LPC) 距离测量^[1], 语音能量阈值, 语音持续时间, 音调, 过零率^[2], 倒谱特征^[3], 语音信号的自适应噪声建模^[4]和周期性测量^[5]等。其中一些算法是在特定应用上实现的, 如泛欧数字蜂窝移动电话服务^[6], 蜂窝网络^[7]和数字无线电话系统^[8]。不幸的是, 这些算法在低信噪比 (Signal to Noise Ratio, SNR) 值情况会存在一些问题, 特别是当噪声是非平稳的时候, 结果更不理想。由于大多数算法采用阈值水平的比较, 因

此无法实现高准确性。通常假定该阈值水平是固定的^[9]或者在静音（语音不活动）间隔中计算。例如，在使用最小均方(Least Mean Squares, LMS)算法的自回归分析中，需要静音间隔来训练有限长单位冲激响应滤波器(Finite Impulse Response, FIR)^[3]。Tucker 研究了一种基于周期性的 VAD 算法^[5]，它可以在 SNR 低至 0dB 的条件下工作。但是对于某些应用，尤其是当环境不稳定时，引用这个算法会让语音质量变得非常差，故需要 SNR 值低于 0dB 时的可靠性实验。

深度神经网络（Deep Neural Network, DNN）的概念要从深度学习（Deep Learning, DL）和人工神经网络（Artificial Neural Network, ANN）说起。DNN 又名深层次的人工神经网络。人工神经网络最初是一种通过模仿动物神经网络行为特征，并且对其加以分布式并行信息处理的数学算法模型。这个概念出自 Warren McCulloch 和 Walter Pitts^[10]，1943 年他们通过提出一种阈值逻辑算法从而创造了神经网络的计算模型。1949 年，Hebb 提出的权重强化法则^[11]为拥有记忆特性和可变性的神经网络奠定了基础。1958 年，在最初提出的计算模型的基础上，Rosenblat 提出了感知器模型^[12]，人工神经网络首次走出理论被应用到工程实际中。如图 1-2 所示，深度神经网络的拓扑结构中主要包括输入层，隐含层和输出层。图 1-3 所示为 DNN 的神经元模型。




图 1-2 深度神经网络结构




图 1-3 神经元模型

1.1.2 课题意义

谷歌、百度、微软、IBM 等拥有大数据的高科技公司近几年来都相继将大量资源投入到深度学习技术的研发中, 深度神经网络在语音识别, 图像识别, 广告搜索点击率 (Click Through Rate, CTR) 预估, 自然语言处理等领域^[19-21]都有广泛应用, 尤其在语音识别领域, 深度神经网络的特有优势让其成为研究热点。

近年来斯坦福大学教授 Manning 等人^[22]将 DNN 应用于自然语言处理领域, 取得了非常显著的成就。递归结构通常存在于自然场景图像、自然语言句子等等不同模态的信息中。Manning 等人发现这类递归结构不但可以用来识别图像或句子所包含的单元, 还可以识别组成整体的单元之间的联系, 他们将含有递归结构的神经网络用于含有最大边缘结构的预测体系结构中, 该网络模型能够成功恢复复杂场景图像和句子中的复杂结构。这个网络模型既可以用于为自然语言句子提供语法分析器, 还可以用于语义场景分割, 注释和分类。对于分割和注释, 他们的算法在基于斯坦福的数据集中获得了最高的准确性, 在分类应用场景中, 也获得了较好的效果。

多年来, 传统的多层感知器 (Multi-Layer Perceptron, MLP) 在语音识别领域一直有被应用, 而当单独使用 MLP 的时候, 其性能远低于使用 GMM-HMM 系统的情况。2011 年微软基于深度神经网络的语音识别研究取得成果, 彻底改变了语音识别原有的技术框架^[23]。微软研究人员使用深度信任网络 (Deep Belief Network, DBN) 对大量的语音数据进行建模, 提出基于大词汇量的语音识别系统的深层神经网络-隐马尔可夫混合模型 (CD-DNN-HMM), 与之前最领先的常规 CD-GMM-HMM 的大词汇量语音识别系统相比, 其误差率减少了 16% 以上。Nair 等^[24]提出利用三阶波尔兹曼机的原理改进 DBN 网络, 并将这种改进的 DBN 网络应用于三维物体识别任务 NORB 数据库, 实验结果显示其预测误差接近历史最低水平, 该网络模型优于 SVM 等浅层模型。K. Cho^[25]等提出了一种基于循环神经网络 (Recurrent Neural Network, RNN) 的 RNNenc 模型, 并将该模型应用于机器翻译。该模型中 RNN 用于将源语言符号序列编码成固定长度的向量和将编码过的向量解码为目标语言的符号序列。这个模型的缺点是存在固定长度, 这个缺陷使得降低网络误差成为最大的难题。为了克服这个问题, D. Bahdanau^[26]等在该模型的基础上, 提出了更优的 RNN 搜索模型。该模型在 ACL2014 机器翻译研讨会中的测评结果显示性能高于 RNNenc 模型。

语音作为最自然便捷的交流方式, 一直是人机通信和交互最重要的研究领域之一。自动语音识别 (Automatic Speech Recognition, ASR) 是实现人机交互尤为关键的技术, 其所要解决的问题是让计算机能够“听懂”人类的语音, 将语音转化为文本。自动语音识别技术经过几十年的发展已经取得了显著的成效。近年来, 越来越多的语音识别智能应用走入了人们的日常生活, 例如苹果的 Siri、微软的小娜和科大讯飞的出国翻译器等。VAD 作为语音识别领域中必不可少的关键技术之一, 这个模块的性能和功耗在整个语音识别系统中起着十分重要的作用。VAD 中的特征提取模块以及语音分

类模块是最核心的两大模块。而这两大模块均满足用神经网络替代的前提条件，随着神经网络的快速发展与广泛应用，将神经网络的算法应用到语音端点检测中势必成为一个新的研究热点。

Florian Eyben^[27]提出了一种新颖的基于数据驱动的 VAD 方法，为了逼近现实生活场景，使用来自 TIMIT 和 Buckeye 语料库的语音，添加各种类型的噪声来获得大量的语音实例。该方法根据看不见的混合测试数据以及四部完整的好莱坞电影组成的真实测试集进行评估，最后取得了显著的改善。基于神经网络的语音活动检测方法在生活中的应用十分广泛，如何提高基于 DNN 的 VAD 系统的鲁棒性，降低电路的功耗，提升其在噪声环境中的识别能力是研究的重点。

1.2 国内外研究现状

1.2.1 VAD 的研究现状

VAD 是许多音频信号处理系统的重要预处理模块。它可以通过仅检测和发送语音信号来提高语音通信系统^[28]的效率，还可以通过滤静音和噪声段帮助实现语音增强算法^[29]或语音识别系统^[30-31]。VAD 的主要挑战之一是降低在低信噪比环境中的运行结果误差。早期的研究主要集中在基于信号处理的声学特征，包括时域能量，基音检测，过零率和几种基于光谱能量的特征，如能量熵，光谱发散和高阶统计^[32]。VAD 最近在低频超声^[33]和单频滤波^[34]领域也有应用。在语音识别中，声学特征对于提高 VAD 的性能研究非常重要。然而，每个声学特征并不能反映人类声音的所有特征。并且在极端的情况下使用这些声学特征不是很有效。因此，将许多特征结合在一起作为输入数据驱动，可以有效地改善 VAD 的整体性能。

VAD 的另一个重要研究分支是统计信号处理。首先分别对语音分布和背景噪声（通常在谱域中）进行模型假设，然后设计统计算法以动态估计模型参数。典型的模型假设包括高斯分布模型^[35-36]，拉普拉斯分布模型^[37]，伽马分布模型^[38]或它们的组合模型^[38]。最流行的参数估计方法是最小均方差估计^[39]。此外，长时背景信息对提高语音端点检测系统的性能有显著作用^[40]。由于模型假设的简单性和参数的在线更新，所以这种方法可以在各种噪声场景中产生合理的结果。在许多情况下，它们比基于能量的方法表现出更优良的特性。但基于统计模型的方法存在局限性。首先，模型假设可能无法完全获取全局数据分布情况，因为模型通常具有的参数太少，并且它们通过有限的本地观察在运行中估计参数。其次，由于参数相对较少，它们在融合多个声学特征时可能不够灵活。此外，大多数方法在纯噪声阶段期间更新参数，当噪声在语音阶段期间快速变化时，可能出现错误的结果。

语音端点检测研究的第三个重点研究分支是机器学习方法，利用机器学习的算法从给定的噪声语料库中训练声学模型，并将模型应用于实际应用中的测试环境。基于机器学习算法的语音端点检测有两个主要的研究目标：一是在训练和测试语料库的噪声场景匹配时提高模型的判别能力；另一个是当测试噪声场景与训练噪声场景不可见或不匹配时，提高模型的泛化能力（即检测精度）以测

试噪声场景。

1.2.2 基于 DNN 的 VAD 研究现状

大多数基于机器学习方法的 VAD 算法集中在如何提高辨别能力上。根据训练语料库是否被手动标记,可以将它们分类为使用未标记的训练语料库的无监督学习,或使用标记的训练语料库的监督学习。许多无监督方法属于降维,其首先从高度变化的高维观测中提取噪声稳健的低维特征,然后将这些特征应用于分类器。它们包括主成分分析^[41],非负矩阵分解^[42]和拉普拉斯^[43]的谱分解。一些机器学习算法直接使用聚类算法,例如 Means Clusterings^[44]和高斯混合模型^[41]。无监督方法能够探索多种特征并从大量的记录数据中训练稳健模型,但是,当语音环境过于复杂使得大多数语音信号在背景噪声中被淹没时,例如 SNR 低于 0dB 的嘈杂噪声,无监督方法很难获得理想的效果。故基于 VAD 的统计信号处理也可以被视为无监督方法,其从一些本地观察对象和累积的历史信息中训练模型。

近年来,深度神经网络及其扩展算法^[45-50]具有很强的大规模语料库可扩展性,即使在极端困难的情况下也能表现出良好的性能,并且在实际应用中具有很大的竞争力。Zhang 和 Wu^[45]提出将标准的 DBN 网络应用于 VAD,实验结果显示比基于 SVM 的 VAD 具有更好的性能,其中网络是在^[31]中预训练的。Zhang 和 Wang^[49]进一步提出通过增加上下文信息从 DNN 得到多个不同的预测结果,实验结果显示在非平稳噪声情况和低 SNR 水平下相对于标准 DNN 都有显著改进。在一些研究^[46-47]中,利用深度递归神经网络来获得历史背景信息,并实现了对高斯混合模型和统计信号处理方法的显著改进。当基于 DNN 的 VAD 应用于看不见的测试场景时^{[47][51]},性能显著下降。一些研究者^{[48][50]}将 DNN 和卷积神经网络(Convolutional Neural Networks, CNN)从大规模的现实世界数据中进行了训练^[52]并证明了令人印象深刻的两个阶段的改进。但是,由于其模型都绑定到给定的通道,仍然不确定如何将模型推广到不同的噪声情景。由于任务设置的限制,结果并没有定量评估模型如何随 SNR 水平变化而变化的情况。

1.3 研究内容与设计指标

1.3.1 研究内容

VAD 作为语音识别处理器的关键模块,其意义在于通过对输入的语音信息进行初步处理,过滤掉各种背景下的噪声,在实时系统中过滤静音部分,在系统接收静音信息时关闭系统部分功能,从而大幅降低系统功耗。VAD 的难点在于声学特征提取和语音分类技术,实现特征提取和语音分类的算法虽然被不断的优化,但是仍然存在电路硬件开销大、能耗高、运算量大且复杂度高以及在低信噪比非平稳噪声中精确度较低等问题。深度神经网络可通过使用具有多个处理层的数学模型来对数

据中的高级抽象进行建模，多重线性和非线性变换，实质是通过构建具有多层隐含层的机器学习模型和海量的训练数据，来学习对象的特征。基于 DNN 的端点检测方法与基于能量、谱熵、基频等传统检测方法相比具有明显优势，特别是引入带噪环境训练技术后，该方法在高噪声环境下表现出优异的性能。

本文结合语音端点检测和深度神经网络的算法特征，设计一种基于 DNN 的高鲁棒性低功耗 VAD 加速器。首先，从 VAD 模型的算法特征出发，分别对 VAD 的核心算法模块，即特征提取和语音分类做优化和实现。针对特征提取模块，优化梅尔频率倒谱系数 (Mel Frequency Cepstrum Coefficient, MFCC) 特征提取方法，并且利用 DNN 代替传统的 MFCC 实现算法，实现快速傅里叶变换 (Fast Fourier Transformation, FFT)、离散余弦变换 (Discrete Cosine Transform, DCT)。利用坐标旋转计算机 (Coordinate Rotation Digital Computer, CORDIC) 算法实现能量谱计算，提高 VAD 的计算速度，降低电路的功耗。针对语音分类模块，对目前主流的语音分类方法进行比较和分析，提出利用 DNN 的方法实现语音分类，提高 VAD 在非平稳噪声和低信噪比下的精确度和鲁棒性；最后，利用 DNN 具有的高度容错性的优势，在 DNN 计算单元中引入数模混合近似计算，利用多阶量化共享乘法器实现计算单元中的乘法单元，利用延时链实现计算单元中的累加单元，基于多阶量化共享乘法器提出 VAD 的动态精度可配方案，大幅降低系统功耗的同时，提高电路能效，有效降低 VAD 的访存开销和运算开销，从而实现语音端点检测系统的高鲁棒性低功耗。

1.3.2 设计指标

本文提出一种基于深度神经网络面向语音活动检测应用的高鲁棒性低功耗加速器。将 DNN 引入到 VAD 的两大核心模块，即语音特征提取模块和语音分类模块，代替传统的算法实现更高辨别度的同时，降低系统的功耗。其设计指标主要有以下两点：

1) 高鲁棒性：目前主流的 VAD 算法利用统计模型实现语音分类，但是计算复杂鲁棒性低，本文提出用 DNN 实现语音分类、FFT 和 DCT，由于 DNN 具有高鲁棒性的优势，故基于 DNN 的 VAD 具有高鲁棒性的特点。

2) 低功耗：为了降低 DNN 的计算功耗，本文提出数模混合近似计算，引入共享乘法器实现乘法运算，引入延时链实现累加运算，并且利用多阶量化共享乘法器实现 VAD 的动态精度可配运算，同时优化 DNN 网络在 VAD 的映射，实现基于 DNN 的高鲁棒性低功耗 VAD 设计。

本文采用 TSMC28nm HPC + 工艺，VAD 加速器的系统面积预估小于 0.6mm^2 ，片上存储的工作电压为 0.8V，VAD 加速器和其他模块的逻辑电源电压为 0.58V，工作频率为 1.6MHz。本文使用 Synopsys HSIM 在 25°C TT 工艺转角条件下进行时序和功耗评估。VAD 的系统功耗预估低于 $10\mu\text{W}$ ，能效预估达高于 30TOPS/W，12dB 下 VAD 的精确度高于 90%。

1.4 论文组织

本文的主体结构和各章节之间的关系如图 1-4:




图 1-4 本文组织结构关系图

第一章为绪论，首先介绍课题背景和研究意义；其次阐述 VAD 在国内外的研究现状，并指出 VAD 加速器的设计难点；最后说明本文的研究内容和设计指标。

第二章首先比较目前主流的几种特征提取算法，分析每个算法的原理和优劣，并且详细介绍 MFCC 算法的每一个步骤，包括语音的预处理算法、FFT、梅尔滤波以及 DCT，通过对不同特征提取算法的性能参数比较显示，MFCC 在 VAD 的实际应用中精确度最高，并且消耗的硬件资源在要求范围内，故本文选用 MFCC 特征提取算法；接下来，分析和比较目前主流的语音分类方法，并且结合实际 VAD 模型应用场景，基于 DNN 的 VAD 系统不仅消耗的硬件资源最少，并且网络精确度也较高，故本文选用 DNN 代替传统的语音分类算法；最后，基于神经网络的良好容错性，引入三种近似乘法计算方法，并将它们与 DNN 的算法特点结合作比较分析。

第三章基于 VAD 的算法流程本文提出 VAD 加速器的硬件设计方案；基于 MFCC 的特征提取算

法设计特征提取模块，其中包括预加重模块、分帧模块、FFT 和 DCT 以及能量谱计算模块，其中的 FFT 和 DCT 利用 AxBench 平台用 DNN 网络实现，能量谱计算模块利用 CORDIC 算法实现，大大降低 VAD 的系统功耗和芯片面积；语音分类模块采用引入近似计算的 DNN 加速器，并且设计并实现 DNN 加速器的运算单元以及多阶量化共享乘法器；最后，提出基于 VAD 的系统结构设计。

第四章基于 DNN 的高鲁棒性低功耗 VAD 系统调度和优化方案如下：首先，设计 VAD 加速器的整体系统调度；接着，对 DNN 网络在 VAD 加速器的映射方案做优化改进，提出采用数模混合近似计算的方法代替第三章提到的全数字的实现方法，延时链代替数字加法器，乘法器使用多阶量化的共享乘法器，将多阶量化的共享乘法器的并行计算、高吞吐率、低功耗的算法优势与神经网络的计算方法紧密结合，使得精确度和功耗都进一步优化；最后，本文提出一种基于 DNN 的动态精度可配运算的 VAD 加速器算法，针对不同的应用场景，不同的精度要求，动态调整共享乘法器的量化阶数，使得在满足精确度的要求下，VAD 的系统功耗被降至最低。

第五章首先介绍本文的实验环境，包括模型验证以及 RTL 级验证环境，并对最后的验证结果进行比较分析。本章首先将提出的多阶量化共享乘法器与标准乘法器实现的 VAD 系统在不同噪声类型不同信噪比下的精确度作分析比较；其次，针对本文提出的基于混合精度近似计算的高能效 DNN 加速器，本章使用 EDA 工具验证多阶量化共享乘法器、MFCC 以及基于数模混合近似计算实现的 VAD 系统的功能和各项性能指标；最后，本章将提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器的性能指标与近几年主流的 VAD 加速器和 DNN 加速器作对比。

第六章对本文的工作做总结和展望。

第二章 VAD 的算法分析与比较

基于 DNN 的高鲁棒性低功耗 VAD 设计首先需要从 VAD 模型的特征提取，语音分类算法，近似算法以及神经网络算法开始分析。通过将基于近似运算的神经网络模型和 VAD 的特征提取和语音分类算法紧密结合，提出基于 DNN 的 VAD 系统。本章首先基于经典 VAD 系统结构，介绍了 VAD 的系统算法流程；然后比较了目前主流的几种特征提取算法，分析了每个算法的原理和优劣，并且详述 MFCC 算法的每一个步骤，利用 AxBench 平台用 DNN 网络实现 FFT 和 DCT，大大降低系统功耗和芯片面积；其次，分别介绍目前主流的几种语音分类方法，并且结合实际的 VAD 模型应用场景，分析各种语音分类算法的利弊；最后，基于神经网络的良好容错性，引入了几种近似乘法计算方法，分析比较了三种近似乘法器的算法原理和优劣。这一章为后续章节中的 VAD 硬件系统设计提供了思路。

2.1 特征提取的算法分析

VAD 主要包括两个核心模块，即特征提取模块和语音分类模块。VAD 系统的算法流程如图 2-1 所示。目前主流的 VAD 特征提取算法包括能量、过零率、自相关以及梅尔频率倒谱系数等。本章将分别介绍目前主流的几种特征提取算法，并分析这几种算法在实际应用场景中被应用到 VAD 模型中的优劣。




图 2-1 基于 DNN 的 VAD 算法流程

MFCC 的实现算法主要包括语音的预处理（包括预加重、分帧以及加窗等）、快速傅里叶变换、梅尔滤波以及离散余弦变换等算法，最后输出语音的特征参数向量，作为语音分类模块的输入。如图 2-2 所示，不同的特征提取方法会直接影响 VAD 模型的精确性。




图 2-2 VAD 不同帧的状态判断结果与真实结果的对比波形图

2.1.1 主流的特征提取算法分析

如图 2-3 所示, 应用在 VAD 中, 主流的特征提取算法包括基于能量、过零率、自相关以及倒谱等。




图 2-3 传统的特征提取算法实现

1) 能量和幅度: 语音段能量是语音和噪声的能量之和, 其计算方法如式 (2.1)。与噪声段的噪声能量相比, 语音段能量明显要大, 因此利用能量和幅度的差异就能判别语音和噪声以及清音和浊音。语音幅度的计算方法如式 (2.2)。基于能量和幅度的特征提取算法实现起来电路简单, 且功耗低, 非常易于实现, 但是当噪声大到和语音一样时, 能量这个特征无法区分语音还是纯噪声。在信噪比低于 10dB 时, 语音和噪声的区分能力会加速下降。式 (2.1) 中 E_n 表示能量, 式 (2.2) 中 A_n 表示幅度。

$$E_n = \sum_{m=0}^{N-1} x_n(m)^2 \quad (2.1)$$

$$A_n = \sum_{m=0}^{N-1} |x_n(m)| \quad (2.2)$$

2) 过零率: 10ms 干净语音样本的过零率在浊音语音的情况下约为 5%~10%, 在清音语音的情况下约为 50%。在干净的语音的情况下, 过零率在静音区间变成零, 在话音区间变为非零。但是, 在实际应用中必然会出现一定程度的背景噪音。因此, 即使在静音间隔中, 由于背景噪声也会产生一些过零点, 导致误判。式 (2.3) 为过零率的计算式, 其中 Z_n 为过零率。

$$Z_n = \frac{1}{2} \sum_{m=0}^{N-1} |\text{sgn}[x_n(m)] - \text{sgn}[x_n(m-1)]| \quad (2.3)$$

$$\text{sgn}[x] = \begin{cases} 1 & x \geq 0 \\ -1 & \text{其他} \end{cases}$$

3) 自相关: 每次能量检测器显示一个帧处于非活动状态时, 零交叉检测器 (Zero Cross Detection, ZCD) 将检查该帧的语音活动并检测信号的所有低能量语音部分。基于过零率的特征提取算法在应用时具有一个致命的缺点, 即当噪声窗口的零交叉满足决策方程时, ZCD 将噪声帧误分类为语音。因此, 需要一种将弱幅度信号与噪声区分的校正方法。自相关函数可以解决这个问题, 这个函数是利用语音信号中的高相关性。基于自相关的特征提取算法保留了语音信号中的大部分信息, 因此它具有多个峰值, 因此需要对信号做详细的预处理。语音的预处理过程使周期更加突出, 同时可以抑

制信号的其他干扰特征。语音和噪声具有不同的相关性。语音的一个明显特征是包含了基频及其多个谐波频率，即使在强噪声场景，谐波这一特征也是存在的。因此可以使用自相关的方法找到基频。在一般的噪声环境下，利用自相关性也能很好地模拟语音信息。但是基于自相关的特征提取算法的计算太复杂，如式 (2.4)，一般不会单独应用于 VAD，只能作为辅助参数。

$$R_n = \sum_{m=0}^{N-1-k} x_n(m) \bullet x_n(m+k) \quad (2.4)$$

图 2-4 显示了传统的特征提取算法在白噪声环境下的语音活动检测结果示例。无论是基于能量、过零率、自相关还是这三种算法的结合算法，最后的精确性都不满足要求。




图 2-4 传统的特征提取算法在白噪声环境下的语音活动检测结果示例

4) 倒谱：基于倒谱的特征提取算法流程如图 2-5 所示。




图 2-5 基于倒谱的特征提取算法流程示意图

首先，将输入的时域信号 $x(n)$ 拆分成两个时域信号相乘的形式，如式 (2.5)：

$$x(n) = h(n) * e(n) \quad (2.5)$$

对时域信号 $x(n)$ 做傅里叶变换，即：

$$X(k) = H(k)E(k) \quad (2.6)$$

接着，对傅里叶变换后的输出结果取 $\log$ ：

$$\log(X(k)) = \log(H(k)) + \log(E(k)) \quad (2.7)$$

其中， $\log(H(k))$ 是低频包络， $\log(E(k))$ 是高频频谱，具体的包络频谱细节图如图 2-6 所示。




图 2-6 频域信号低频包络以及高频频谱细节图

然后，再对式 (2.7) 的输出结果进行反傅里叶变换：

$$IDFT(\log(X(k))) = IDFT(\log(H(k))) + IDFT(\log(E(k))) \quad (2.8)$$

最后可以利用倒谱分析将信号分解，两个信号的卷积转化为两个信号的相加：

$$x'(n) = h'(n) + e'(n) \quad (2.9)$$

尽管可以用梅尔频谱本身作为声音特征，但使用倒谱可以进一步提高识别性能。抛开预加重和梅尔刻度转换，倒谱的定义可以看作是频谱对数的频谱，即将标准幅度谱的幅度值先取对数，然后形象化对数谱使其看起来像声音波形。倒谱这个单词 Cepstrum 正是将单词 Spectrum（频谱）的前四个字母颠倒而来，频谱是将时域信号变换为频域信号，倒谱则是将频域信号又变换回时域信号；在波形上，倒谱与频谱有相似的波形，即如果频谱在低频处有个峰值，则倒谱在低倒谱系数上也有峰值，如果频谱在高频处有个峰值，则倒谱在高倒谱系数上也有峰值。所以如果是为了检测音元，可以用低倒谱系数；如果是检测音高，则可以用高倒谱系数。倒谱系数的优点是其不同系数的变化是不相关的，意味着高斯声学模型无需表现所有倒谱特征的协方差，因而大大减少了参数数量。

2.1.2 基于 MFCC 的特征提取算法分析

基于 MFCC 的特征提取算法是倒谱算法的其中一种，也是目前应用最广泛最有优势的一种特征提取算法，即在语音识别领域，将语音物理信息，包括频谱包络和细节，进行编码运算得到的一组特征向量。梅尔频率倒谱是声音的短期功率谱的表示，并且基于对数频谱的离散余弦变换，其对准频率的非线性梅尔刻度。梅尔频率倒谱与倒谱之间的区别在于，梅尔频带在梅尔刻度上等距离分布，这与人类听觉系统的响应相近^[59]。MFCC 的算法流程如图 2-7 所示，主要包括语音的预处理，即预加重、分帧、加窗，快速傅里叶变换，梅尔滤波，能量谱计算以及离散余弦变换。




图 2-7 MFCC 特征提取算法流程

1) 分帧

为了避免窗边界对信号的遗漏，因此对帧做偏移的时需要帧叠，即帧与帧之间需要重叠一部分，如图 2-8 所示。




图 2-8 分帧示意图

因为语音信号是快速变化的，而傅里叶变换适用于分析平稳的信号，利用语音的短时平稳性，对连续的语音信号采样后分帧，则计算帧数的过程如式（2.10）：

$$\text{帧数} = \frac{s - 30}{10} \quad (2.10)$$

其中 s 为一段语音的毫秒数。故将不定长的音频切分成固定长度的小段，这一步称为分帧。一般取 10~30ms 为一帧，取帧长的一半作为帧移，每次位移一帧的二分之一后再取下一帧，这样可以避免帧与帧之间的特性变化太大。每帧信号通常要与一个平滑的窗函数相乘，让帧两端平滑地衰减到零，这样可以降低傅里叶变换后旁瓣的强度，取得更高质量的频谱。帧与帧之间会有重叠，否则，由于帧与帧连接处的信号会因为加窗而被弱化，这部分的信息就会丢失。傅里叶变换是逐帧进行的，为的是取得每一帧的频谱。一般只保留幅度谱，丢弃相位谱。

2) 预加重

在语音信号中，由于声门气流波的影响，每倍频会衰减 12dB，而唇腔辐射是每倍频增加 6dB，因此总的效果是每倍频衰减 6dB，为了弥补这 6dB，故本文采取预加重技术，如图 2-9 所示。




图 2-9 预加重效果图

由于每倍频会衰减 6dB，高频部分的能量一般比较低，提高高频部分的能量使得高频能量和低频能量大致相等，尽量弥补每倍频损失的 6dB。故，预加重以帧为单位进行，目的在于加强高频。数学算式如下：

$$s(n) = s(n) - k * s(n-1), \forall n \in N \quad (2.11)$$

k 是预加重系数，范围为[0,1)，常用 0.97， N 是每一帧的长度，从式 (2.11) 可以看出每一帧的第一个数需要特殊处理。

3) 加窗

语音在长范围内是不停变动的，没有固定的特性无法做处理，所以将每一帧代入窗函数，窗外的值设定为 0，其目的是消除各个帧两端可能会造成的信号不连续性。因为之后要做 FFT，而一个信号的 FFT 与这个信号的周期信号的 FFT 相同，所以如果这个信号边缘不平滑，那么这个信号的周期信号在现实中是很少遇到的，这样就没有意义了。故，每帧信号通常要与一个平滑的窗函数相乘，让帧两端平滑的衰减到零，这样可以降低傅立叶变换后旁瓣的强度，取得更高质量的频谱。常用的窗函数有方窗、汉明窗、汉宁窗等，好的窗函数也能减弱频谱丢失。根据窗函数的频域特性，常采用汉明窗，其对应的窗函数如式 (2.12)：

$$S'_n = \left\{ 0.54 - 0.46 \cos \left(\frac{2\pi(n-1)}{N-1} \right) \right\} S_n \quad (2.12)$$

加窗过程其实就是将输入数据 $data[0:n-1]$ 与权重系数 $w[0:n-1]$ 对应相乘。

4) FFT 的算法分析与优化

语音的预处理之后得到的仍然是时域信号，为了提取语音特征，首先需要将时域信号转换为频域信号。傅里叶变换可以将信号从时域转到频域。傅里叶变换可以分为连续傅里叶变换和离散傅里叶变换，因为本文用的是数字音频（而非模拟音频），所以本文采用离散傅里叶变换，如式 (2.13)：

$$X(k) = \sum_{j=1}^N x(j) w_N^{(j-1)(k-1)} \quad (2.13)$$

从式 (2.13) 可以看出, 傅里叶变换的计算复杂度较高, 因此应用中一般使用 FFT。信号频率即组合产生复杂信号的简单信号的频率, 通常简单信号的频率范围很广, 采样频率即模拟到数字的转换过程中, 需要对模拟信号进行采样, 每秒内的采样点数量就是采样频率。通常人的声音的频率大概在 3~4kHz, 因此语音识别通常使用 8kHz 或者 16kHz 的频率提取特征。16kHz 采样率的音频, 傅里叶变换之后的频率范围为 0~8kHz。如图 2-10 所示为实现 FFT 的蝶形算法。传统的算法实现很复杂, 会带来很大的硬件开销, 因此本文提出用 DNN 网络代替复杂蝶形运算实现 FFT。




图 2-10 实现 FFT 的蝶形算法

傅里叶变换将时域信号转换成频域信号, 每个频带范围的能量大小不一, 不同音素的能量谱不一样。能量谱的计算如式 (2.14):

$$\text{magnitude} = \sqrt{\text{real}^2 + \text{image}^2} \quad (2.14)$$

5) 梅尔滤波的算法分析

MFCC 的分析着眼于人耳的听觉特征, 由于人耳所听到的声音的高低与声音的频率不成线性正比关系, 因此使用梅尔频率尺度更符合人耳的听觉特征。梅尔频率与实际频率的具体关系如图 2-11:




图 2-11 梅尔三角滤波结构图

取每个三角滤波器的频率带宽内所有的信号幅度加权和作为带通滤波器的输出，然后对所有带通滤波器的输出做对数运算，再进一步做离散余弦变换即得到多维的 MFCC 特征向量。

6) DCT 的算法分析与优化

DCT 是傅里叶变换的一种特殊形式，相比于 FFT 只有实部，没有虚部。DCT 具备以下特性：对于一般的语音信号，DCT 输出的结果的前几个系数特别大，后面的系数比较小，因此可以忽略。DCT 的输出结果一般是 40 个特征向量；实际应用中，一般保留前 26 个输出，进一步压缩了数据。假设对信号取 Log 之后得到 N 维的特征向量，则 DCT 的计算式如 (2.15)：

$$C_i = \sqrt{\frac{2}{N}} \sum_{j=1}^N m_j * \cos\left(\pi * \frac{i}{N} * (j-0.5)\right), \forall i \in [1, M] \quad (2.15)$$

其中 N 是取 log 之后的特征维度， M 是做完 DCT 之后的特征维度。DCT 的实质是去除各维信号之间的相关性，将信号映射到低维空间。

表 2-1 统计了传统的特征提取算法与 MFCC 在不同信噪比下的漏判率和误判率。其中 HR0 表示漏判率，即被误判为非语音帧的帧数占有所有语音帧的帧数的比率，而 HR1 为误判率，即被误判为语音帧的帧数占有所有非语音帧的帧数的比率。从表中可知，基于 MFCC 的特征提取算法在三种不同信噪比的环境下的 HR0 和 HR1 值均最小。故本文选择 MFCC 作为 VAD 的特征提取算法。

表 2-1 传统的特征提取算法与 MFCC 在不同信噪比下的漏判率和误判率比较

特征提取算法	SNR(dB)	HR0(%)	HR1(%)
能量	-5	92	76
	0	93	77
	5	94	78
过零率	-5	90	70
	0	91	71
	5	92	73
自相关	-5	88	66
	0	89	67
	5	92	69
MFCC	-5	59	40
	0	61	38
	5	63	36

2.2 语音分类的算法分析

VAD 的语音分类模块根据特征提取得到的 MFCC 参数判断信号是语音还是非语音。目前主流的语音分类算法有门限法、统计模型法等。这些语音分类算法在实际应用到 VAD 模型中各有优劣。本节将详细介绍目前主流的语音分类算法，并选择最合适的算法应用到 VAD 模型中。

2.2.1 主流的语音分类算法分析

目前主流的语音分类算法主要有基于门限的方法和统计模型等算法，其中统计模型算法主要有高斯混合模型(Gaussian mixture model, GMM)、隐马尔可夫模型 (Hidden Markov Model, HMM) 等。

1) 门限：门限通常是根椐训练数据集特征预先得到的，对于噪声变化的场景，需要使用自适应门限，可以将能量 $a = f(E), a \in E_0, E_1$ ，其中 E_0 表示能量最小值， E_1 表示能量最大值能量，对应的门限为 a_0 和 a_1 ，那么可得自适应门限：

$$a = \begin{cases} a_0, E \leq E_0 \\ \frac{a_0 - a_1}{E_0 - E_1} E + a_0 - \frac{a_0 - a_1}{1 - \frac{E_1}{E_0}}, E_0 < E < E_1 \\ a_1, E \geq E_1 \end{cases} \quad (2.16)$$

大部分情况都可以使用平滑策略来更新门限：

$$\hat{a} = \omega a + (1 - \omega) a_{new} \quad (2.17)$$

比较常用的基于门限的语音分类算法是基于短时能量和过零率的双门限端点检测。图 2-12 表示了整个能量 VAD 双门限算法的具体实现流程框图。若分别对短时能量和过零率设置两个门限值 $Energy_{low}$ ， $Energy_{high}$ 和 Zcr_{low} ， Zcr_{high} ，且 $Energy_{high} > Energy_{low}$ ， $Zcr_{high} > Zcr_{low}$ ；接下来可以计算一帧的短时能量 $Energy$ 和过零率 Zcr ，若 $Energy > Energy_{low} \&\& Zcr > Zcr_{low}$ 进入过度段，若 $Energy > Energy_{high} \&\& Zcr > Zcr_{high}$ ，此时还不能断定语音开始，继续计算几帧短时能量和过零率，若出现 $Energy > Energy_{high} \&\& Zcr > Zcr_{high}$ ，则可判定语音开始。




图 2-12 能量 VAD 双门限算法流程图

基于门限的语音分类实现方法计算简单，但是检测要求很高，要求特征空间是线性可分的，但实际的应用场景很难满足测试要求。

2) 统计模型法：对于 HMM 模型，首先我们假设 Q 是所有可能的隐藏状态的集合， V 是所有可能的观测状态的集合，即：

$$Q = \{q_1, q_2, \dots, q_N\}, V = \{v_1, v_2, \dots, v_M\} \quad (2.18)$$

其中， N 是可能的隐藏状态数， M 是所有的可能的观察状态数。对于一个长度为 T 的序列， I 对应的状态序列， O 是对应的观察序列，即：

$$I = \{i_1, i_2, \dots, i_T\}, O = \{o_1, o_2, \dots, o_T\} \quad (2.19)$$

其中，任意一个隐藏状态 $i_t \in Q$ ，任意一个观察状态 $O_t \in V$ 。HMM 模型做了两个很重要的假设：

齐次马尔科夫链假设：即任意时刻的隐藏状态只依赖于它前一个隐藏状态。如果在时刻 t 的隐藏状态是 $i_t = q_i$ ，在时刻 $t+1$ 的隐藏状态是 $i_{t+1} = q_j$ ，则从时刻 t 到时刻 $t+1$ 的 HMM 状态转移概率 δ_{ij} 可以表示为：

$$\delta_{ij} = P(i_{t+1} = q_j | i_t = q_i) \quad (2.20)$$

这样 δ_{ij} 组成马尔科夫链的状态转移矩阵 A ：

$$A = [\delta_{ij}]_{N \times N} \quad (2.21)$$

观测独立性假设：即任意时刻的观察状态仅依赖于当前时刻的隐藏状态。这也是一个为了简化模型的假设。如果在时刻 t 的隐藏状态是 $i_t = q_i$ ，而对应的观察状态为 $o_t = v_k$ ，则该时刻观察状态 v_k 在隐藏状态 q_i 下生成的概率为 $b_j(k)$ 如式 (2.22)：

$$b_j(k) = P(o_t = v_k | i_t = q_j) \quad (2.22)$$

这样 $b_j(k)$ 可以组成观测状态生成的概率矩阵 B ：

$$B = [b_j(k)]_{N \times M} \quad (2.23)$$

除此之外，需要一组在时刻 $t=1$ 的隐藏状态概率分布 Π ： $\Pi = [\pi(i)]_N$ ，其中 $\pi(i) = P(i_1 = q_i)$ 。

一个 HMM 模型，可以由隐藏状态初始概率分布 Π ，状态转移概率矩阵 A 和观测状态概率矩阵 B 决定。 Π ， A 决定状态序列， B 决定观测序列。因此，HMM 模型可以由一个三元组 λ 表示：

$$\lambda = (A, B, \Pi) \quad (2.24)$$

基于 GMM、HMM 等统计模型的语音分类算法相比于门限法提高了 VAD 模型在低信噪比和非平稳噪声下的精确度，但是运算量太大，电路功耗大，并且会受具体应用环境的限制，不同噪声环境下需要不同的模型。图 2-13 所示为 VAD 在不同的信噪比（5/10/15dB）条件下的语音状态判断的结果。由于字间短无声间隔的能量通常较低，因此这些间隔大概率被视为非语音状态。在使用基于

GMM 的语音分类算法的情况下, 这种趋势最为明显。由于 HMM 的状态使用持续时间效应, 故基于 HMM 的算法比 GMM 带来更优越的结果。但是不管是 GMM 还是 HMM, 在发生频繁突发剪辑的情况下都很可能导致实时语音相关算法的性能变差。基于双层 HMM 的 VAD 的性能比其他传统方法的性能更优异, 但是精确度仍然不够高。




图 2-13 不同噪声环境下传统的语音分类的波形框图 (a) 5dB (b) 10dB (c) 15dB

2.2.2 基于 DNN 的语音分类算法分析

在语音识别中, 神经网络很多情况下会被用来代替传统语音分类方法, 例如高斯混合模型, 实现语音分类算法, 计算语音帧的状态输出概率。但是一直以来神经网络只是作为一种替代方法而存

在，和传统的语音分类算法相比并没有表现出绝对的优势。近年来，随着深度神经网络的广泛应用，神经网络的优势才得以充分展现，并且开始全面代替传统的语音分类建模的方法。

DNN 网络具有一个十分显著的优势，即层次性学习能力。DNN 在较低层次上对于学习通用模式只需应用低层次 DNN，而对于复杂模式则可以利用较高层次来学习，以满足精度要求。通过模仿人类的学习方式，DNN 可以更充分的利用模型参数。利用 DNN 的强大的学习能力，通过从 VAD 的特征提取中获取特征参数的输出作为网络输入，完成语音分类的任务。这一过程无需人为干预，网络自动完成。并且，DNN 具有非常强大的学习复杂分类任务的能力。这使得 DNN 能从大量的数据中学习多种噪音模式并且各种噪声环境可以互不干扰。如图 2-14 为 DNN 的基本网络结构图，DNN 的网络架构很简单，主要由三部分组成，即输入层、隐含层与输出层。




图 2-14 DNN 基本网络结构

基于 DNN 实现的 VAD 系统不但精确度高，并且设计简单，面积小，功耗低。故本文选用 DNN 的方法实现 VAD 的语音分类。首先在大规模标注的语音库中，基于 DNN 的分层学习能力和学习复杂分类任务的能力，以音素区分性为学习目标，利用深度神经网络模型从 MFCC 特征提取参数中学习多种语音和非语音模式，实现帧层次上的语音和非语音的判断；接下来实现适用于不同噪声环境下的 VAD 模型检测。DNN 网络可以表示为一个从输入到输出的映射函数 $f_{\theta}: R^M \rightarrow R^K$ ，其中 M 是 MFCC 特征向量维度，本文取 26 维， K 表示音素集的大小， θ 表示网络中所有可变参数。假设输入的 MFCC 特征向量为 $x \in R^M$ ，输出 $y \in \{0,1\}$ 。DNN 的优化目标函数如式 (2.25)：

$$E(\theta) = -\sum_{n=1}^N \sum_{k=1}^K \left\{ y^{(n)} \ln f_k \left(x^{(n)} \right) \right\} \quad (2.25)$$

其中， N 表示训练样本数。根据 (2.25) 式对 DNN 模型参数进行优化，即可得到音素区分模型。

将某一帧的 MFCC 特征向量输入到 DNN 网络中，依上述方法训练 DNN 模型，将所有语音音素对应的输出加和，即可得到该帧为语音的概率，通过与实验中设定好的阈值作比较，判断该帧为语音还是非语音。

2.3 近似乘法算法分析与实现

本文提出 DNN 算法实现语音分类、FFT 以及 DCT，基于神经网络的良好容错能力，并且考虑到神经网络中乘法的功耗占比很高，本文在 DNN 的乘法单元设计中引入近似乘法，使得 DNN 在满足精度要求的前提下，降低 VAD 系统的功耗和面积。

2.3.1 截断乘法算法

截断乘法器的实质是牺牲一定的精度降低乘法器的面积和功耗。截断乘法器被广泛应用于数字信号处理领域^{[63][64][65]}。由于 DNN 网络的设计原理和数字信号处理原理具有一定的相似性，即可以通过降低计算精度降低面积、功耗，提升性能，并且截断乘法器引入的误差对于整体的结果影响很小，故截断乘法器在 DNN 网络的设计中，可以作为一种备选方案。

假设两个 n 位的乘数 X 和 Y 相乘，如标准乘法器的计算式 (2.26) 所示，获得 $2n$ 位的乘积 P 。

$$P = XY = \sum_{i=0}^{2n-1} P_i 2^i = \left(\sum_{i=0}^{n-1} x_i 2^i \right) \left(\sum_{i=0}^{n-1} y_i 2^i \right) \quad (2.26)$$

其中 x_i ， y_i 和 P_i 分别代表 X ， Y 和 P 的第 i 位。

如式 (2.27) 所示，可将式 (2.26) 改写成两部分和表示，高有效部分 (the Most Significant Part, MSP) 和低有效部分 (the Less Significant Part, LSP)。

$$P = MP + LP = \sum_{i=0}^{2n-1} P_i 2^i = \sum_{i=n}^{2n-1} P_i 2^i + \sum_{i=0}^{n-1} P_i 2^i \quad (2.27)$$

计算结果被拆为两部分，可以明显看出两部分的重要性大相同，即 MSP 代表 P 中的高有效位，而 LSP 代表 P 中的低有效位。如果在计算过程中忽略低有效位，则可以达到简化乘法计算的目的，这就是截断乘法器的核心设计思想。但是若直接忽略低有效部分，必然会引入误差。故为了在一定程度上减少误差，需要引入修正项 (Input Correction, IC)。基于上述思路，可将式 (2.28) 改写为：

$$P \approx MP + IC = \sum_{i=n}^{2n-1} P_i 2^i + IC \quad (2.28)$$

2.3.2 对数乘法算法

对数乘法器作为高效的乘法器之一，大多被应用到计算速度比精确度更为重要的领域^{[66][67][68]}。对数乘法引入了从整数系统到对数系统的操作数转换机制。操作数 N_1 和 N_2 的乘法分三个阶段实现：取乘数的对数；乘数的对数的加法；反对数操作。基于迈切尔算法 (Mitchell Algorithm, MA)^[65] 的近似对数乘法基本上会采用节省硬件面积的查找表方式，但是，基于查找表的 MA 算法有一个明显的弊端：对数和反对数不能精确计算，故需要近似计算对数和反对数。对于一个整数 N ，其二进制表示可写为：

$$N = 2^k \left(1 + \sum_{i=j}^{k-1} 2^{i-k} Z_i \right) = 2^k (1 + x) \quad (2.29)$$

其中 k 是最高非零位的开始位置，即数 N 的首“1”位置， Z_i 是 N 的第 i 个比特位置处的值， x 是尾数， j 的大小取决于数字的精度（对于整数 j 取 0）。对 N 以 2 为底取对数，可得：

$$\log_2(N) = \log_2(2^k(1 + \sum_{i=j}^{k-1} 2^{i-k} Z_i)) = k + \log_2(1 + x) \quad (2.30)$$

$\log_2(1+x)$ 一般是近似值，故基于对数的算法是计算速度与准确度之间的折衷。由式（2.30）可将两个数的乘法表示为式（2.31）：

$$\log_2(N_1 N_2) = (k_1 + k_2) + \log_2(1 + x_1) + \log_2(1 + x_2) \quad (2.31)$$

故两个操作数相乘的积可以通过计算二者的对数，对数的加法和反对数求得，对数和反对数的计算是一个难题，用 x 近似表示 MA 算法中表达式 $\log_2(1+x)$ ，两个数的乘积的对数可表示为它们的首“1”位置参数 k 和尾数之和，如式（2.32）所示：

$$\log_2(N_1 N_2) \approx k_1 + k_2 + x_1 + x_2 \quad (2.32)$$

对于 16 位数字，参数 k_1 ， k_2 的范围是 0 到 15。分数 x_1 和 x_2 的范围是 $[0,1)$ 。乘法的最终 MA 算法近似（其中 $P_{true} = N_1 \cdot N_2$ ）取决于来自尾数和进位，由式（2.33）给出：

$$P_{MA} = (N_1 N_2)_{MA} = \begin{cases} 2^{k_1+k_2}(1 + x_1 + x_2), & x_1 + x_2 < 1 \\ 2^{k_1+k_2+1}(x_1 + x_2), & x_1 + x_2 \geq 1 \end{cases} \quad (2.33)$$

式（2.33）中的最终近似结果需要将尾数之和与“1”进行比较。参数 k_1 ， k_2 的总和决定了积的最高位。积的最终结果为将 $(1+x_1+x_2)$ 或者 (x_1+x_2) 左移 (k_1+k_2) 或 $(1+k_1+k_2)$ 位。若 $x_1+x_2 < 1$ ，则将 $(1+x_1+x_2)$ 左移 (k_1+k_2) 位得到最终结果，否则将 (x_1+x_2) 左移 $(1+k_1+k_2)$ 位得到最终结果。

MA 算法虽然简单易实现，但是误差较大，且相对误差随着尾数值为“1”的位数增加而增加。对于 16 位乘法，MA 乘算法的最大可能相对误差大约为 11%，平均误差约为 3.8%^{[69][70]}。且这些误差均为正值，为了修正这种误差，Babić^[66]等提出了一种改进的对数乘法器——迭代对数乘法算法。所提出的迭代对数乘法算法将式（2.33）中的近似对数项做了简化，引入了可实现多级近似精度的迭代对数乘法算法，在开始计算近似结果时立即计算校正项。

本章通过实验，得到了 16 位迭代对数乘法器的迭代次数和计算精度的关系，如表 2-2 所示，结果显示，迭代对数乘法器能根据迭代次数的增加而迅速收敛，当迭代次数超过三次时，误差降低到 2% 以下。

表 2-2 16 位迭代对数乘法器迭代次数和精度的关系

次数	1	2	3	4	5
误差 (%)	24.821	5.434	1.439	0.390	0.088

2.3.3 共享乘法算法

如图 2-15 所示，共享乘法运算结构主要包括共享乘法阵列单元以及选择移位单元。共享乘法阵列单元的输入为输入数据，其中包括 8 个子计算单元， $1 \times \text{input}$ 、 $2 \times \text{input}$ …… $8 \times \text{input}$ 。例如当权重为 1010_1101 时，即权重的高四位为 1010（十进制的 10），低四位为 1101（十进制的 13），那么权重和输入数据相乘，即 $1010_1101 \times \text{input}$ ，可以等价拆分成权重低四位和高四位分别和输入数据相乘的和的结果，即 $(1010 \times \text{input}) \ll 4 + (1101 \times \text{input})$ 。1101 $\times \text{input}$ ，即 $13 \times \text{input}$ ，那么低四位的控制单元会控制选择器选择共享乘法阵列里面的 $13 \times \text{input}$ ，控制移位器不移位，输出权重低四位和输入数据相乘的结果。同样地，权重高四位的控制单元会控制选择器选择共享乘法阵列里面的 $5 \times \text{input}$ ，并且控制移位器左移一位得到 $10 \times \text{input}$ 输出，此结果通过移位器左移 4 位然后和刚刚权重低四位得到的相乘结果相加，得到最终输出。




图 2-15 共享乘法器结构框图

2.3.4 近似乘法算法比较分析

第二章提到了截断乘法器和对数乘法器，为了解决加速器设计中乘法运算延时长和功耗大的问题，三种近似乘法算法各有特点。截断乘法器具有简单直接，易于实现的特点，但是误差比较大功耗面积也高，性能没有显著提高；迭代对数乘法器相比于截断乘法器误差更小，计算延时更短，但是电路面积和功耗占比较大；多阶量化共享乘法器，则具有精度可调、灵活可变、节约计算资源、计算延时短。功耗面积小等特点。表 2-3 中给出了几种乘法器的具体对比，其中截断乘法器的数据来自于 Garofalo^[58]，迭代乘法器数据来自于 Babić^[57]，共享乘法器通过实验给出。从表中可以看出三种乘法器各有优势，截断乘法器优势主要在于功耗和面积都有节省，而迭代对数乘法器则主要在于计算延时的优势上，而多阶量化共享乘法器则在性能上表现最为优越，功耗和面积上也具有较好的优势。

表 2-3 三种近似乘法器和标准乘法器的参数对比

乘法器	误差	功耗节省比例	面积节省比例
截断乘法器 ^[58]	3.06%	16.0%	16.0%
迭代度对数乘法器 ^[57]	2.43%	19.0%	2.43%
共享乘法器	0	76%	62%

虽然三种近似乘法器各有优势，但是综合上述性能参数评估，多阶量化共享乘法器为本文的最佳选择。原因主要在于，截断乘法器和迭代对数乘法器都不能很好的契合 DNN 在 VAD 的应用场景，相较之下，截断近似乘法器性能上没有明显提升，不能满足 VAD 系统低延时的要求，迭代对数乘法器，虽然计算延时小，但是电路面积和功耗都很大，这不满足本文的设计要求。相比之下，多阶量化共享乘法器电路简单，功耗小，精确度可根据实际应用场景控制变换，符合 VAD 在不同应用场景中的不同精度要求，在功耗和性能之间折中应用。共享乘法架构引入共享乘法阵列进一步极大地优化了能效和延时。特别地，针对神经网络等具有复杂计算特点的应用具有明显的计算优势。神经网络的计算特点决定了同一个输入数据需要和 N 个的权重相乘，而共享乘法器的共享乘法阵列中的子单元可以列出同一个输入数据与多个常数的乘积值， N 个权重可以同时连接到 N 个选择移位单元的输入接口，实现一个时钟周期内 N 个权重与一个输入数据的 N 个乘积输出。解决了电路计算中芯片功耗过高，延时过长，芯片硬件资源利用不充分等难题。对于不同的应用场景和网络模型有不同的计算精度要求。通过拆分电路中的乘法运算，共享子运算单元，可显著提高计算资源的利用率和降低计算功耗。

2.4 本章小结

本章首先比较了目前主流的几种特征提取算法，包括能量幅度、过零率以及自相关和基于 MFCC 的特征提取算法，分析了每个算法的原理和利弊，并且详细介绍了 MFCC 算法的每一个步骤，包括语音的预处理算法、FFT、梅尔滤波以及 DCT，通过对不同特征提取算法的性能参数比较，发现 MFCC 在 VAD 的实际应用中精确度最高，并且消耗的硬件资源在要求范围内，因此本文选用 MFCC 特征提取算法；接下来，分别介绍了目前主流的语音分类方法，包括基于门限、统计模型 HMM 以及基于 DNN 的语音分类方法，并且结合实际的 VAD 模型应用场景，分析各种语音分类算法的利弊发现，基于 DNN 的 VAD 系统不仅消耗的硬件资源最少，并且网络精确度也较高，故本文选用 DNN 代替传统的语音分类算法；最后，基于神经网络的良好容错性，引入了几种近似乘法计算方法，介绍了三种常用的近似乘法器的算法分析，并将近似乘法算法与 DNN 算法相结合进行分析。相较于截断乘法器和迭代对数乘法器，共享乘法器功耗低、精确度高，且其算法优势更符合 DNN 网络的实现。

本章为第三章中基于 DNN 的高鲁棒性低功耗 VAD 系统的硬件设计和第四章 VAD 的系统优化提供了设计依据。

第三章 基于 DNN 的高鲁棒性低功耗 VAD 硬件设计

为了实现 VAD 的高鲁棒性,即提高 VAD 在低信噪比和非平稳噪声下的语音和非语音的命中率,并且实现 VAD 的低功耗,即降低 VAD 的电路复杂度和运算复杂度,第二章提出了利用 DNN 的方法代替 FFT、DCT 以及语音分类模块的实现,并且在 DNN 计算单元中引入近似乘法。本章将立足于第二章的分析基础以及其改进的方案,设计 VAD 加速器的预加重模块、分帧模块、能量谱计算模块以及梅尔滤波模块。在 DNN 加速器的计算单元中设计并实现一种多阶量化的共享乘法器。最后实现基于 DNN 的高鲁棒性低功耗 VAD 加速器的整体架构设计方案。

3.1 特征提取模块的优化设计

3.1.1 预加重模块设计

由第二章的算法分析可知,预加重的目的是为了对语音的高频部分进行加重,去除口唇辐射的影响,增加语音的高频分辨率,使得信号的频谱变得平缓。FIR 预加重滤波器用差分方程的表示如式 (3.1):

$$S[i] = S[i] - 0.94S[i-1], \forall i \in [0, N] \quad (3.1)$$

其中, $S[i]$ 为原始语音信号序列, N 为语音长度,式 (3.1) 显示其在时域上的特性。本文设计了一种实现预加重功能的数字电路,为了降低 VAD 系统的功耗,预加重模块中的乘法利用移位代替实现。预加重模块的实现原理如下:

因为式 (3.1) 中的第二项的系数 0.94 可以等效为 15/16, 所以将上面的式子 (3.1) 可以转化为:

$$S[i] = S[i] - \frac{15}{16}S[i-1] = S[i] - \left(S[i-1] - \frac{S[i-1]}{16} \right) \quad (3.2)$$

式 (3.2) 中,括号中的最后一项,除以 16 可以用移位器右移 4 位来实现,将除法运算替换为移位运算,通过降低计算复杂度,降低 VAD 加速器的功耗和面积。预加重模块的硬件设计如图 3-1,即输入原始信号序列 $S[i]$, 经过延时模块得到延时一个周期后的信号 $S[i-1]$, 接着延时后信号经过移位器右移 4 位得到 $\frac{S[i-1]}{16}$, 最后将这三个信号经过组合逻辑电路进行加减运算得到预加重的输出。




图 3-1 预加重模块硬件设计框图

3.1.2 分帧模块设计

基于第二章对语音预处理的算法分析，傅里叶变换适用于分析平稳的信号，不能直接对快速变化的语音信号进行分析。在语音识别中，由于要保证一帧内既有足够多的周期，又不会变化很剧烈，因此帧长不宜太长或太短。合适的帧长可以在语音的预处理过程中避免语音信息的丢失和保证语音识别的精确性。对信号进行分帧是语音预处理中十分重要的一项工作。

图 3-2 所示为分帧模块的电路框图设计。在本文中，语音一帧取 256 个点，为了使帧与帧之间的平滑过渡，采用交叠分帧的方法。帧移取 1/2 帧长。FIFO#1 的存储大小为一帧语音长度，即 256×8 比特，信号输入到预加重模块后得到的输出数据写入到 FIFO#1 中。为了实现帧移交叠，FIFO#1 的读时钟频率设计为写时钟率的 2 倍，而 FIFO#2 的读写时钟频率和 FIFO#1 的读时钟频率相同，FIFO#2 的存储大小是 FIFO#1 的一半，即 128×8 比特。FIFO#1 和 FIFO#2 的输出作为多路选择器的输入，多路选择器选择输出最后分帧结果。经过分帧模块的处理，完成帧长为 20ms，帧移为 10ms 的分帧操作。




图 3-2 分帧模块硬件设计框图

3.1.3 FFT 与 DCT 的设计

在语音的预处理之后，为了提取语音特征，首先利用傅里叶变换将时域信号转换为频域信号，接着计算信号的能量谱。传统的 FFT 硬件结构设计如图 3-3 所示。




图 3-3 基于传统算法的 FFT 硬件设计

AxBench^[53]是与 NPU 编译器结合用于近似计算的测试平台。AxBench 是用 C++和 CUDA 编写的，旨在探索不同领域相对应的应用的近似计算方案。基于 AxBench 的平台，对应用的部分源代码区域进行标记，然后从被标记区域的开始和结束两端通过源代码收集数据，将被标记的区域代码用神经网络替换，使用收集到的数据对神经网络进行反复训练，通过不停地修改参数训练数据以模拟标记区域，最终用训练有素的神经网络替代原始的代码区域。同时，在整个训练过程中，AxBench 平台还能选出神经网络的最佳拓扑结构。表 3-1 的实验结果显示利用 3 层 DNN 网络结构实现的 DCT 和 FFT 的软件误差分别为 0.19%和 0.23%。

表 3-1 利用不同的 DNN 网络实现的 FFT 和 DCT 的误差比较

应用	网络结构	软件误差	硬件误差
FFT	1x4x4x2	7.22%	9.34%
	1x32x2	0.23%	5.29%
DCT	1x2x2x1	5.72%	8.28%
	1x16x1	0.19%	4.32%

利用传统的算法实现的 FFT 硬件结构复杂，并且会占整个 VAD 系统芯片的面积比重很大，会影响整个芯片的功耗。本文利用 AxBench 平台，通过设置迭代次数等参数，训练得到 FFT 和 DCT 的神经网络最佳拓扑结构。用 DNN 的算法代替传统的 FFT、DCT 算法，大大降低 FFT 和 DCT 模块的电路面积和功耗。如图 3-4 所示为实现 FFT 的 DNN 网络结构。





图 3-4 实现 FFT 的 DNN 网络架构。

3.1.4 能量谱计算模块设计

为了满足本文的设计目标，本文引入 CORDIC 算法代替传统的算法实现能量谱求值。利用 CORDIC 算法，整个运算过程只有加法与移位运算，同时采用流水线设计，使得效率大大提升。假设在 XY 坐标系中有一个点 $P_1(X_1, Y_1)$ ，将 P_1 点绕原点旋转 θ 角后得到点 $P_2(X_2, Y_2)$ 。如图 3-5 所示：


 图 3-5 XY 坐标系中 P_1 旋转至 P_2 示意图

当点 (X_1, Y_1) 转过 θ 角之后，到达点 (X_2, Y_2) ，有如下等式关系：

$$X_2 = r \cos(\theta_0 + \theta) = X_1 \cos \theta - Y_1 \sin \theta = \cos \theta (X_1 - Y_1 \tan \theta) \quad (3.3)$$

$$Y_2 = r \sin(\theta_0 + \theta) = X_1 \sin \theta + Y_1 \cos \theta = \cos \theta (Y_1 + X_1 \tan \theta) \quad (3.4)$$

旋转 n 次后得到的值如下：

$$X_n = \cos \theta_0 \cos \theta_1 \cdots \cos \theta_n (X_{n-1} - Y_{n-1} \tan \theta_n) \quad (3.5)$$

$$Y_n = \cos \theta_0 \cos \theta_1 \cdots \cos \theta_n (Y_{n-1} + X_{n-1} \tan \theta_n) \quad (3.6)$$

令 $k = \cos \theta_0 \cos \theta_1 \cdots \cos \theta_n$ ，则当每次旋转的角度值 θ_n 确定后，即 k 值是个定值，每次的 $\tan \theta_n$ 也确定了。利用上述原理，当初始坐标 $P_1(X_1, Y_1)$ 确定，经行循环旋转迭代，逐步向 X 轴逼近，最后得到的 X 值便是 $magnitude = \sqrt{X^2 + Y^2}$ ，即对应的能量谱值。




图 3-6 CORDIC 处理单元硬件结构框图

图 3-6 所示为 CORDIC 基本处理单元的两种硬件结构，即 CORDIC 之圆周系统旋转处理单元和向量处理单元。从两种硬件框图中可以得出，不管是哪种硬件结构，CORDIC 基本处理单元都是由三个加法器和一个用于存储角度的查找表（Look Up Table, LUT），以及两个移位器构成。基本处理单元的简单结构正好反映了 CORDIC 算法的优势。除了移位量和存储角度不同，每次迭代所用到的处理单元基本结构是一致的，本章分析比较了三种 CORDIC 算法硬件实现架构，分别是 CORDIC 算

法硬件实现的串行结构、并行结构以及并行流水结构。




图 3-7 CORDIC 算法硬件实现的三种结构

这三种硬件架构的框图如图 3-7 所示。从图中可知：1) 串行结构其实是对 CORDIC 处理单元的分时复用，因此占用的资源最少，但是控制单元的设计就难免更复杂，导致时序控制较为繁琐，系统处理速度变低；2) 并行结构是基于上述串行结构的一种扩展，即对每次的迭代都赋予了独立的 CORDIC 处理单元，因此无需控制电路的存在，只需做移位、加减操作。这也是并行结构与串行结构中 CORDIC 处理单元最大的不同。显然，相比于串行结构，并行结构虽然去除了控制单元电路，提高了系统处理速度，但是消耗的硬件资源显著增加。3) 为了进一步地提高系统处理速度，本文采取对并行结构添加流水寄存器的改进方法，即为并行流水结构。

并行流水结构可以有效地缩短了关键路径，使得关键路径的长度由原来的并行结构的 N 个 CORDIC 处理单元变为 1 个 CORDIC 处理单元。因此，并行流水结构具有最快的处理速度，并且消耗的硬件资源在本文设计的承受范围之内

3.2 DNN 加速器设计

基于 DNN 的高鲁棒性低功耗 VAD 系统架构中的关键模块之一就是 DNN 加速器模块。DNN 加速器可以用来实现语音分类和基于 MFCC 特征提取算法中的 FFT 模块以及 DCT 处理单元。DNN 加速器的具体硬件设计框图如图 3-8 所示。DNN 加速器主要由 4×4 个处理单元 (Process Element, PE) 构成的二维的计算阵列，一个 sigmoid 函数实现模块，数据存储器，控制单元以及直接内存存取 (Direct Memory Access, DMA) 组成。二维计算阵列用于实现输入数据和权重的乘加运算；通过 sigmoid 激活函数在神经网络中引入非线性因素，使得神经网络可以任意逼近任何非线性函数；数据存储器用于存储输入数据和权重，控制单元用于整个 DNN 加速器模块的控制，DMA 实现把外设的数据读入内存或把内存的数据传送到外设。




图 3-8 DNN 加速器模块硬件结构框图

相比于传统的 FFT、DCT 以及语音分类的硬件实现方法，利用 DNN 网络的硬件设计更能提高 VAD 系统的识别精确度，提高 VAD 的鲁棒性，并且降低基于 DNN 的 VAD 加速器的功耗和面积，有效降低 VAD 系统的计算复杂度。为了进一步的提高 VAD 系统的性能，降低系统功耗，下文将对 DNN 加速器的计算单元中进行优化设计和实现。

3.2.1 DNN 加速器中的运算单元设计

运算单元是 DNN 加速器的运算阵列中最基本的处理单元，用来模拟反向传播（Back propagation, BP）神经元的功能，即输入数据和相应的权重相乘得到部分和，部分和经过累加单元得到数据总和，最后累加的数据总和经过激活函数的变换得到最终输出。因此运算单元中至少包含乘法器、加法器、选择器以及激活函数模块以满足运算需求。




图 3-9 运算单元结构框图

运算单元的结构框图功能分析如图 3-9 所示：其中的 C0、C1 和 C2 是控制信号，C0 和 C1 控制运算单元实现乘法或加法或者累加功能，C2 控制计算单元的输出类型为直接输出或者经过激活函数输出。反向传播神经元的输入来源有很多种：权重可以来自寄存器或者权重输入输出缓存；输入数据可以来自阵列内部存储器、数据输入输出缓存、相邻运算单元的输出以及寄存器。加法器的输入

可以来自常数、部分和以及自身寄存器的输出。因此，运算单元中需要加入不同的多路选择器以选择合适的信号来源。寄存器在运算单元的设计中也非常关键，通过控制寄存器就可以实现运算单元的时序逻辑。




图 3-10 运算单元具体硬件结构

最终的运算单元结构细节如下图 3-10 所示，即运算单元中共有五个寄存器和六个多路选择器。图中所示的多路选择器 0 选择部分和的来源，多路选择器 1 选择输入数据的来源，多路选择器 3 选择权重的来源。多路选择器 2 和多路选择器 4 一起联合控制选择加法器的输入。DEMUX0 选择数据成为运算单元的输出或者作为相邻单元的输入。运算单元的设计实现了权重和输入数据的乘法计算、加法计算以及部分和计算。

3.2.2 多阶量化共享乘法器的设计

在 DNN 加速器中，乘法的功耗占整个系统功耗的大部分，故降低乘法的功耗可以大大降低 DNN

加速器的整体功耗。针对神经网络的优良容错性，第二章引入了近似乘法概念，即采用近似乘法器实现 DNN 加速器计算单元中的乘法单元。截断乘法器具有简单直接，易于实现的特点，但是误差比较大，功耗面积也高，性能没有显著提高；迭代对数乘法器相比于截断乘法器误差更小，计算延时更短，但是电路面积和功耗占比均比较大。本节设计了一种多阶量化的共享乘法器。假设两个 8 比特的权重和输入数据相乘，即乘积可以拆分成权重低四位和高四位分别和输入数据相乘的和的结果：

$$W * N = W_{MSB} * N + W_{LSB} * N \quad (3.7)$$

八阶量化的共享乘法运算结构主要包括共享乘法阵列单元以及选择移位单元。假设共享乘法阵列单元的输入为输入数据，其中包括八个子计算单元， $1*input$ 、 $2*input$ …… $8*input$ ，可精确表示全部 16 种 4 比特数相乘的输出结果，如表 3-2 所示。

表 3-2 八阶量化共享乘法器可精确表示的数

共享乘法阵列	左移一位	左移两位	左移三位
$1*input$	$2*input$	$4*input$	$8*input$
$3*input$	$6*input$	$12*input$	
$5*input$	$10*input$		
$7*input$	$14*input$		
$9*input$			
$13*input$			
$15*input$			

例如当权重为 1010_1101 时，即权重的高四位为 1010（十进制的 10），低四位为 1101（十进制的 13），那么权重和输入数据相乘，即 $1010_1101*input$ ，可以等价拆分成权重低四位和高四位分别和输入数据相乘的和的结果，即：

$$1010_1101*input = 1010*input * 2^4 + 1101*input \quad (3.8)$$

$1101_2*input$ 即 $13_{10}*input$ ，低四位的控制单元会控制选择器选择共享乘法阵列里面的 $13_{10}*input$ ，并且控制单元控制移位器不移位，最后输出权重低四位和输入数据相乘的结果。同样地，权重高四位的控制单元会控制选择器选择共享乘法阵列里面的 $5_{10}*input$ ，并且控制移位器左移一位得到 $10_{10}*input$ 输出。最后将权重高四位与输入数据相乘的结果左移四位和权重低四位与输入数据相乘的结果相加，得到最终的 8 比特权重与输入数据的乘积输出。

四阶量化共享乘法器可精确表示 12 种 4 比特数乘积结果，如表 3-3 所示。相比于八阶量化共享乘法器，精确度下降，但是电路面积和功耗降低。

表 3-3 四阶量化共享乘法器可精确表示的数

共享乘法阵列	左移一位	左移两位	左移三位
1*input	2*input	4*input	8*input
3*input	6*input	12*input	
5*input	10*input		
7*input	14*input		

1010_1101*input 输入到二阶量化共享乘法器中，低四位的控制单元会控制选择器选择共享乘法阵列里面的 $7_{10} * input$ ，并通过控制单元控制移位器左移 1 位，得到 $14_{10} * input$ ，最后输出权重低四位和输入数据相乘的结果。权重高四位的控制单元会控制选择器选择共享乘法阵列里面的 $5_{10} * input$ ，并且控制移位器左移一位得到 $10_{10} * input$ 输出。最后将权重高四位与输入数据相乘的结果左移四位和权重低四位与输入数据相乘的结果相加，得到最终的 8 比特权重与输入数据的乘积输出。

二阶量化共享乘法器可精确表示 8 种 4 比特数乘积结果，如表 3-4 所示。因此相比于八阶量化共享乘法器，精确度进一步下降，但是电路面积和功耗进一步地降低。

表 3-4 二阶量化共享乘法器可精确表示的数

共享乘法阵列	左移一位	左移两位	左移三位
1*input	2*input	4*input	8*input
3*input	6*input	12*input	

1010_1101*input 输入到二阶量化共享乘法器中，低四位的控制单元会控制选择器选择共享乘法阵列里面的 $3_{10} * input$ ，并通过控制单元控制移位器左移两位，得到 $12_{10} * input$ ，最后输出权重低四位和输入数据相乘的结果。权重高四位的控制单元会控制选择器选择共享乘法阵列里面的 $1_{10} * input$ ，并且控制移位器左移三位得到 $8_{10} * input$ 输出。最后将权重高四位与输入数据相乘的结果左移四位和权重低四位与输入数据相乘的结果相加，得到最终的 8 比特权重与输入数据的乘积输出。

一阶量化共享乘法器取消了共享乘法阵列，即乘法完全由移位和加法表示。一阶量化共享乘法器可精确表示 5 种 4 比特数乘积结果，如表 3-5 所示。因此相比于八阶量化共享乘法器，精确度进一步下降，但是电路面积和功耗大幅度降低。

表 3-5 一阶量化共享乘法器可精确表示的数

共享乘法阵列	左移一位	左移两位	左移三位
1*input	2*input	4*input	8*input

1010_1101*input 输入到二阶量化共享乘法器中，低四位的控制单元会控制选择器选择共享乘法阵列里面的 $1_{10} * input$ ，并通过控制单元控制移位器左移三位，得到 $8_{10} * input$ ，最后输出权重低四位和输入数据相乘的结果。权重高四位的控制单元会控制选择器选择共享乘法阵列里面的 $1_{10} * input$ ，

并且控制移位器左移三位得到 $8_{i0} * input$ 输出。最后将权重高四位与输入数据相乘的结果左移四位和权重低四位与输入数据相乘的结果相加，得到最终的 8 比特权重与输入数据的乘积输出。

图 3-11 中所示多阶量化共享乘法器，主要由共享乘法阵列和 8 个选择移位（S-S）单元组成。共享乘法阵列有 N ($N=8,4,2,1$) 个子计算单元，可以表示 N 个权重和输入数据的乘积，乘积结果存储在 N 个寄存器中。由于所有 S-S 单元共享一个共享乘法阵列，因此一个处理单元可以在一个周期内执行多个乘法计算。对于一个 8 比特的权重，选择移位单元通过权重高四位或者低四位的控制单元选择共享乘法阵列的子计算单元的计算结果，然后控制模块控制移位器的移位操作，最后将高四位权重与输入数据相乘的结果左移四位和低四位权重与输入数据相乘的结果相加得到最后的输出值。共享乘法阵列可与多个选择移位单元同时工作。本文在共享乘法架构的基础上对共享乘法阵列进行多阶量化，将共享乘法阵列分为四个量化级别进行实验，包括 8 阶、4 阶、2 阶以及 1 阶量化。 N 阶量化的共享乘法阵列包含 N 个子计算单元，1 阶量化的共享乘法器直接将输入数据输入到选择移位单元以获得乘法结果，取消了共享乘法阵列，硬件结构简单，功耗大大降低，但是乘法的精度也会降低。故共享乘法单元的量化阶数的可配置性可以满足不同噪声环境的不同精度要求。相比于普通的乘法器，共享乘法阵列极大地降低了乘法器的电路功耗，提高了电路的吞吐率。




图 3-11 共享乘法器硬件架构设计

3.3 基于 DNN 的 VAD 系统结构

VAD 加速器的设计难点主要有：1) 传统的特征提取算法 MFCC 的硬件实现比较复杂，硬件开销大，涉及到 FFT、DCT 等复杂模块；2) 传统的语音分类算法，门限法计算简单，但是要求特征空间是线性可分的，实际应用中检测要求很难达到；统计模型的方法提高了低信噪比和非平稳噪声

下的端点检测性能，但是运算量太大，功耗大，由于受具体应用环境的限制；机器学习的方法利用神经网络复杂模式上的高度灵活性来学习各种语音和噪声模式，实现对语音片段更准确的检测，该方法在高噪声环境下表现出优异的性能，但是多噪声环境下，训练过程耗时长，功耗大；3) 基于 DNN 实现的 VAD 加速器，DNN 网络的结构决定了它的基础运算为大量的乘累加运算，而乘法一直是硬件资源消耗多、功耗大的算术运算，乘法运算的功耗，决定了 DNN 加速器的系统功耗。

针对 VAD 加速器的设计难点，本章提出如图 3-12 所示的基于 DNN 的 VAD 加速器原型系统架构。顶层架构包括一个用 ARM7T DMI 实现的系统控制器，一个 VAD 处理器，一个 8K 字节的静态随机存取存储器（Static Random-Access Memory, SRAM）作为系统内存，一个 SPI Flash 和几个系统辅助模块调度。所有模块均与 AMBA2.0 AHB 总线兼容，并连接到 32 位 AHB 系统总线模块。其中，VAD 处理器由预加重模块，分帧模块，梅尔滤波器，能量谱计算模块，DNN 加速器，控制器和数据存储器、权重存储器以及配置存储器组成，每个存储器都是 8K 字节的 SRAM。DNN 加速器通过控制器的配置用于处理语音分类和语音特征提取的 FFT 和 DCT 计算。




图 3-12 基于 DNN 的 VAD 加速器系统结构图

3.4 本章小结

基于特征提取、语音分类以及 DNN 算法，本章首先基于 MFCC 的特征提取算法设计了特征提取模块，其中包括预加重模块、分帧模块以及能量谱计算模块；接着，实现了 DNN 加速器的硬件设

计,并且详细介绍了 DNN 加速器的运算单元设计,采用多阶量化共享乘法器作为计算单元中的乘法单元,实现了多阶量化共享乘法器的硬件设计;最后,针对 VAD 加速器的设计难点,设计并实现了基于 DNN 的高鲁棒性低功耗 VAD 系统架构。

第四章 基于 DNN 的高鲁棒性低功耗 VAD 系统调度和优化方案

本章基于第三章的内容对基于 DNN 的高鲁棒性低功耗 VAD 设计做了更深入的优化和调度设计。首先,本章将介绍基于 DNN 的 VAD 加速器的系统架构优化;接着,对 DNN 网络在 VAD 系统上的映射方案做了优化改进,提出采用数模混合近似计算的方法代替第三章提到的全数字的实现方法,即采用延时链代替数字加法器,乘法器使用多阶量化的共享乘法器,将多阶量化的共享乘法器的并行计算、高吞吐率、低功耗的算法优势与神经网络的计算方法紧密结合,使得精确度和功耗都进一步优化;最后,本章提出基于 DNN 的动态精度可配 VAD 设计与实现,即针对不同的应用场景,不同的精度要求,动态调整共享乘法器的量化阶数,使得在满足精确度的要求下系统功耗被降至最低。

4.1 基于 DNN 的 VAD 系统调度方案

本文采用的 VAD 模型主要由两部分组成:特征提取模块和语音分类模块。特征提取模块用于提取输入语音信号的特征值,其输出是 26 维梅尔频率倒谱系数(MFCC);语音分类模块通过对基于 MFCC 的特征提取算法的 26 维向量输出进行分类,判断输出结果为语音还是噪声。特征提取模块包括以下任务:预加重,分帧,512 点 FFT,能量谱、梅尔滤波以及 DCT。本章的 VAD 设计,帧长度为 30ms,为了保证帧内的平稳性,将帧叠定为 20ms。在基于 MFCC 实现的 VAD 系统中,特征提取中的 512 点 FFT 和 DCT 以及语音分类包含大量的乘法和加法运算,这将导致 VAD 的系统功耗达不到设计要求。因此,本文采用 DNN 的方法实现 FFT、DCT 以及语音分类。由于 DNN 具有很好的容错能力,因此本文进一步给出了一种具有近似计算的可重构架构,以降低能耗。本文提出的 DNN 的基本结构是一个三层的全连接网络,每层都有可配置的神经元。基于 DNN 的基本结构,本文实现了两个包含不同数量神经元的网络,其中实现语音分类的 DNN 拓扑结构包含 26 个输入节点,512 隐含层节点和 2 个输出节点;而用来实现 FFT 和 DCT 的 DNN 拓扑结构包含 1 个输入节点,32 隐含层节点和 2 个输出节点。与传统的 VAD 模型设计相比,基于 DNN 的 VAD 系统不仅可以降低 FFT、DCT 和语音分类的计算复杂度,还可以降低每个操作的计算精度要求。

图 4-1 所示为 VAD 加速器的结构细节,VAD 系统由预加重模块、分帧模块、能量计算模块、DNN 加速器以及存储器组成,其中能量谱计算模块采用并行流水的 CORDIC 硬件实现结构代替传统的方案实现,DNN 加速器中的计算单元采用数模混合近似计算电路代替传统的全数字电路实现,利用模拟延时链实现 DNN 网络的累加单元,利用多阶量化共享乘法器实现 DNN 网络的乘法单元,其中的延时链由时钟上升沿触发模块和时钟下降沿触发模块组成,多阶量化共享乘法器由共享乘法



第三章提到了基于 DNN 的高鲁棒性低功耗 VAD 加速器的硬件实现方案, VAD 加速器的系统结构由特征提取模块, 即包括预加重模块结构、分帧模块以及能量谱计算, 和 DNN 加速器模块组成。其中, DNN 加速器中的运算单元设计采用数字电路设计方法, 乘法单元采用多阶量化共享乘法器,

累加单元采用传统的加法器实现。本文提出一种数模混合近似计算的方法代替传统的数字实现方法，利用延时链代替数字加法器实现 DNN 网络的累加功能，将共享乘法器的算法优势与神经网络的算法特点完全相结合，大幅提高网络的吞吐率，降低系统的功耗。

4.2.1 基于数字方法实现的 DNN 加速器

DNN 网络的基本计算式如下：

$$S_1 = f(D_1W_{1,1} + D_2W_{1,2} + D_3W_{1,3} + \dots + D_NW_{1,N}) \quad (4.1)$$

式 (4.1) 中 D_i 表示第 i 个数据， $W_{1,j}$ 表示第一行的第 j 个权重。明显看出，实现式 (4.1) 需要大量的加法器，这不但影响计算的速度，更关键的是共享乘法器的并行计算的优点没有得到充分发挥。基于全数字方法的传统 VAD 加速器，其中的 DNN 加速器的计算树状图如图 4-2 所示。




图 4-2 基于数字方法实现的 DNN 加速器计算树状图

假设有一个 DNN 网络，其某一层输入为 M 个神经元，本层具有 N 个神经元，输出 P 个神经元，输出会经过非线性函数将结果输出。在全并行结构的算法中，DNN 对应的伪代码如式 (4.2) 所示：

$$\begin{aligned} & \text{for}(i = 0; i < M; i++) \{ \\ & \quad S_{1,i+1} = S_{1,i} + D_{i+1} \lceil W_{1,i+1}; \\ & \quad S_{2,i+1} = S_{2,i} + D_{i+1} \lceil W_{2,i+1}; \\ & \quad \dots \\ & \quad S_{N,i+1} = S_{N,i} + D_{i+1} \lceil W_{N,i+1}; \} \end{aligned} \quad (4.2)$$

式中的 D 表示输入数据， W 表示对应的权重系数， S 表示每一层的部分和，所有的部分和 $S_{1,i+1} \dots S_{N,i+1}$ 进行并行计算。具体的计算过程对应的数据流图 (Data Flow Diagram, DFG) 如图 4-3 所示。对于第 i 次循环，将第 i 个输入数据 D_i 和 N 个神经元的权重分别相乘，然后分别进行累加。若有 M 个输入数据，则循环需要进行 M 次，累加操作也需要 M 次。如完成一次神经元的乘累加操

作的执行时间都是 1 个 Cycle，全并行结构所需要计算时间，则其时间复杂度为：

$$T_{FP} = M + 1 \quad (4.3)$$




图 4-3 全并行结构 DFG 图

全并行结构建立在完成乘累加的硬件资源大于等于神经元 N 的基础上，这种映射方法虽然易于理解，但是对硬件要求极高，很容易造成硬件资源浪费和结构不灵活。

4.2.2 基于数模混合近似计算的 DNN 加速器

为了将共享乘法器的算法优势更好地应用到 DNN 网络中，本文提出一种基于数模混合近似计算的 DNN 网络实现方案，即利用延时链实现模拟加法器。其计算树状图如图 4-4 所示：




图 4-4 基于数模混合近似计算的 DNN 加速器计算树状图

延时链将图 4-4 中的权重和输入数据的乘积全部相加，但是一条链只可以实现 N 个 1 比特数相加，如果权重和输入数据的乘积为 16 比特数，那么就需要 16 条链实现累加。计算式如下：

$$\begin{cases} S_1[1] = S_{1,1}[1] + S_{1,2}[1] + S_{1,3}[1] + \dots + S_{1,N}[1] \\ S_1[2] = S_{1,1}[2] + S_{1,2}[2] + S_{1,3}[2] + \dots + S_{1,N}[2] \\ S_1[3] = S_{1,1}[3] + S_{1,2}[3] + S_{1,3}[3] + \dots + S_{1,N}[3] \\ \vdots \\ S_1[N] = S_{1,1}[N] + S_{1,2}[N] + S_{1,3}[N] + \dots + S_{1,N}[N] \end{cases} \quad (4.4)$$

基于延时链的加法单元由 8 个延时链和 8 个时间数字转换器（Time Digital Convertor, TDC）组成。该电路一次实现由迭代控制器控制的 $N \times 16$ 个数据的总和，并将结果一次传输到电路单元。乘法单元的结果被传输到延时链中以进行逐位累加操作，然后将“1”的数量相加并转换为延迟时间。最后，每条延时链的延时信号由 TDC 量化为数字信号。图 4-5 给出了基于延时链的累加单元的原理示例。




图 4-5 基于延时链的累加单元的原理示例

对于输入数据的每一位设计一条延时单元延时可控的延时链，反相器链由两种针对不同时钟边沿触发的可控延时块构成。如图 4-6 所示，图中的 del1 为时钟上升沿触发可控延时块，del2 为时钟下降沿触发可控延时块。




图 4-6 延时单元电路结构

对于 del1, $D=0$ 时, M2 开启, 信号通过管 M4、M6、M2 到输出端口 Y, 延时为 Δt , $D=1$ 时, M2 截止信号通过管 M4 到输出端口 Y, 延时为 $2\Delta t$; 对于 del2, $D=0$ 时, M3 开启, 信号通过管 M3、M5、M1 到输出端口 Y, 延时 Δt , $D=1$ 时, M3 截止信号通过管 M3 到输出端口 Y, 延时为 $2\Delta t$ 。将时钟上升沿触发可控延时块和时钟下降沿触发可控延时块相连使用, M 级延时块相连就形成一条计算 M 个 1 比特数的延时链, 再根据精度控制模块得出的结果使用相应条数的延时链进行求和的计算。全连接层每层的计算规模具有差异性, 为了降低计算的复杂度、减小数据调度, 计算阵列必须适应不同网络层的计算规模。阵列迭代控制是基于计算阵列延时信号的可叠加性, 根据每层网络计算量的大小动态调整阵列的迭代次数, 保证每次阵列的计算可以得到一个输出。如图 4-7 所示, 为迭代延时链求和阵列:




图 4-7 迭代延时链求和阵列设计

基于延时的近似求和模块将每条链上的“1”的个数转化成延时的长短，接着需要经过量化操作将延时转化成数字量。因为每级延时的时间很短，在 40ps 左右，用传统的锁存器高频时钟采样，其时钟要求很高，且功耗比较大。所以本文设计了一种新型的时间数字转换模块（Time Digital Converter, TDC），只需要 8 级延时块和 8 个锁存器，且每个锁存器只需采样一次，大大的降低了量化模块的功耗问题，TDC 模块结构如图 4-8 所示。TDC 采用二进制搜索的量化方式，对于待量化延时信号按二进制位进行判断，量化 28 个加数的延时信号，只需采样 8 次即可。




图 4-8 时间数字转化模块设计结构

采样时钟由经过延时块的边沿信号充当，对应二进制每一位上的采样时钟，其构成的延时块相应的分级，如图 4-9 所示。如采样第 7 位数据位上的数值时，所需要的延时块为 27 倍的延时，采样量化最低位上的数据需要的延时块为 1 倍的延时。量化设计的延时块与计算延时单元采用同种结构与工艺，可以解决延时链的延时受 MOS 管工艺、温度、电压等影响以及与标准的采样时钟不匹配的问题。




图 4-9 TDC 内部延时块设计

模拟计算中因为 MOS 管工艺、温度等不可控环境的影响会导致一定的计算误差。通过分析误差模型，设计相应的纠错部件，并且引入在网络训练中考虑电路计算误差的方法设计容错性网络，可以显著减少电路的计算误差。延时链数模混合计算电路的误差主要分为两种情况，一种是误差大小和延时链中“1”出现的个数有关，一种是误差大小和延时链中“1”出现的分布有关。对于“1”的

分布型误差，分析得出为 del1 与 del2 延时块不匹配导致的，将 del1 与 del2 合成一个电路单元，可以有效解决分布误差问题，如图 4-10 所示。对于“1”的数量误差，可以采用不均匀加权量化等级的方式，对误差进行统计分析，对不同量程范围的量化等级进行加权处理，从而有效减小误差。




图 4-10 延时链改进方案

如图 4-11 所示，本文提出的基于数模混合近似计算的 DNN 加速器包含三个处理单元：基于多阶量化共享乘法器的乘法处理单元；基于延时链的累加处理单元；激活函数处理单元。本文提出的 DNN 加速器中，乘法处理单元由 16 个多阶量化共享乘法器组成，每个共享乘法器由共享乘法阵列和 8 个选择移位单元（S-S）组成。共享乘法阵列用于计算输入数据和常数 N ($N = 1, 3, 5 \dots 15$) 的乘积，8 个选择移位单元共享一个共享乘法阵列。控制单元通过选择共享乘法阵列中的子计算单元并进行移位操作，选择移位单元可以计算权重较高 4 位或较低 4 位和输入数据的乘法结果。在本文提出的 DNN 加速器中，有 8 个累加处理单元，每个累加处理单元是一个基于时间延迟的加法单元。在每个累加处理单元中，有 8 条延时链（每条延时链计算 16 个 1 比特数的加法）和 8 个时间数字转换器。激活函数单元主要由加法器，寄存器和 sigmoid 模块组成。

本文提出的 DNN 加速器是一个三层的全连接网络，每层都有可配置的神经元，主要操作是乘法和加法。可以使用三阶的数字-模拟-数字混合计算机制来计算 DNN 网络。首先，乘法处理单元计算输入数据和权重的乘法。每个乘法处理单元包含一个共享乘法单元，并输出八个权重和一个输入数据的乘积。基于本文提出的算法，16 个共享乘法器可以同时计算 16 个输入数据与常数的乘积，累加处理单元累加乘法处理单元的乘法结果。累加处理单元中的一条延时链可以计算十六个 1 比特数据的累加和。在每条延时链中，输入数据有数字信号被转换为具有相应宽度的脉冲信号。然后，这些具有不同延迟宽度的脉冲信号将逐一累加。每个累加处理单元中的时间数字转换器可以将具有不同延迟宽度的累加信号量化为每个比特数据的累加结果。8 个累加处理单元可以计算 8×16 个输入

数据的累加结果；最后，激活函数处理单元计算每个累加处理单元的最终累加结果，并将累加结果暂时存储在寄存器中，然后传输到 sigmoid 模块以获得最终的计算结果。




图 4-11 基于数模混合计算的 DNN 加速器计算单元设计

4.3 基于 DNN 的 VAD 动态精度可配方案

在实际的 VAD 应用中，噪声环境错综复杂，不同的语音识别应用对精度的要求也不一致。对于精度要求高的语音识别应用，可以通过损失一定精度的方法达到降低功耗的目的；对于精度要求低的语音识别应用，可以通过提高电路复杂度，即增加功耗补偿精度。

在 DNN 加速器中，乘法的功耗占整个系统功耗的大部分，故降低乘法的功耗可以大大降低 DNN 加速器的整体功耗。利用神经网络的优良容错性，引入了近似乘法概念，即采用近似乘法器实现 DNN 加速器计算单元中的乘法单元。神经网络的计算特点决定了同一个输入数据需要和 N 个的权重相乘，而共享乘法器的共享乘法阵列中的子单元可以列出同一个输入数据与多个常数的乘积值， N 个权重可以同时连接到 N 个选择移位单元的输入接口，实现一个时钟周期内 N 个权重与一个输入数据的 N 个乘积输出。解决了电路计算中芯片功耗过高，延时过长，芯片硬件资源利用不充分等难题。对于不同的应用场景和网络模型有不同的计算精度要求。通过拆分电路中的乘法运算，共享子运算单元，对权值和输入的运算采用多阶量化，可显著提高计算资源的利用率和降低计算功耗。

基于第三章中提到的多阶量化共享乘法器，即八阶量化共享乘法器、四阶量化共享乘法器、二

阶量化共享乘法器以及一阶量化共享乘法器,将多阶量化共享乘法器的算法优势与 VAD 的算法设计相结合,本文提出基于 DNN 的 VAD 的动态精度可配方案。其具体的算法思想如下:即针对不同的应用场景,可以通过片上训练的方式动态调整共享乘法器的量化阶数,使得精确度和功耗达到最优。如图 4-12 所示,具体实施步骤如下:首先初始化权值,使用训练数据集对 DNN 进行训练,使用测试数据集对预训练的 DNN 进行测试,最终得到网络初始精度 A;然后,初始化共享乘法器的量化阶数为一阶,用一阶量化的共享乘法器替换原始网络中的标准乘法器,并再次使用训练数据集来训练预先训练的 DNN,测试网络的准确性,得到一阶量化后的网络准确度 B;最后,比较 B 和 A 以查看是否满足网络精度要求。如果不满足,提高共享乘法器的量化阶数,使用二阶量化的共享乘法器,再次训练,重复上述步骤一直到网络精度达到要求。通过动态调整共享乘法器的阶数,调整 DNN 的精度。




图 4-12 基于 DNN 的 VAD 动态精度可配计算方案

表 4-1 表示基于不同量化阶数的共享乘法器的 VAD 加速器,其 AUC 值和功耗节省比例的比较。从实验结果可以看到,不管是使用 Aurora、Wall Street 还是 Speech commands 语音库,随着量化阶数的降低,VAD 加速器的 AUC 值逐渐下降,即 VAD 的精确度降低,但是功耗节省比例升高,即 VAD 加速器的功耗变得更低。故针对高精度要求的语音环境,应使用高阶量化的共享乘法器,而对于精度要求不高的语音环境,应使用低阶量化的共享乘法器。例如 Aurora、Wall Street 应使用 2 阶以上的共享乘法器,而对于 Speech commands 可以使用 1 阶量化共享乘法器,即在保证精确度的同时,可以将 VAD 系统的功耗降低至最小。通过基于 DNN 的 VAD 动态精度可配方案,针对高精度要求的应用环境使用高阶量化共享乘法器,针对低精度要求的应用环境使用低阶量化共享乘法器,保证精确度满足要求的前提下,将 VAD 的系统功耗降至最低,实现基于 DNN 的高鲁棒性低功耗 VAD 设计。

表 4-1 基于不同量化阶数共享乘法器的 VAD 加速器的 AUC 和功耗比较

语音库	共享乘法器量化阶数	AUC	功耗节省比例
Aurora	8 阶	96.13%	62%
	4 阶	92.45%	68%
	2 阶	90.25%	72%
	1 阶	72.27%	82%
Wall Street	8 阶	90.32%	65%
	4 阶	85.22%	69%
	2 阶	83.19%	74%
	1 阶	66.23%	83%
Speech commands	8 阶	99.10%	69%
	4 阶	96.32%	70%
	2 阶	92.11%	74%
	1 阶	83.28%	85%

4.4 本章小结

本章基于第三章的内容对基于 DNN 的高鲁棒性低功耗 VAD 设计做了进一步的优化设计。首先，对 VAD 加速器的系统调度方案做了详细介绍；接着，对 DNN 网络在 VAD 加速器上的映射方案做了优化改进，采用数模混合近似计算的方法代替第三章提到的全数字的实现方法，采用延时链代替数字加法器，乘法器使用多阶量化的共享乘法器，将多阶量化共享乘法器的并行计算、高吞吐率、低功耗的算法优势与神经网络的计算方法紧密结合，使得精确度和功耗都进一步优化；最后，本章提出一种基于 DNN 面向 VAD 应用的动态精度可配算法，即针对不同的应用场景、不同的精度要求，动态调整共享乘法器的量化阶数，针对高精度要求的应用场景，使用高量化阶数的共享乘法器，针对低精度要求的应用场景，使用低量化阶数的共享乘法器，使得 VAD 系统在满足精确度的要求下功耗被降至最低。

第五章 验证及结果分析

本文设计实现了一种基于 DNN 的高鲁棒性低功耗 VAD 加速器。本章首先将提出的多阶量化共享乘法器与标准乘法器实现的 VAD 系统在不同噪声类型不同信噪比下的精确度作分析比较；其次，针对本文提出的基于 DNN 的高鲁棒性低功耗 VAD，本章使用 EDA 工具验证多阶量化共享乘法器、MFCC 以及基于数模混合近似计算实现的 VAD 系统的功能和各项性能指标；最后，本章将提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器的性能指标与近几年主流的 VAD 加速器作对比，更直观地展示本文提出的各项优化方案对 VAD 加速器的性能的影响。

5.1 基于 DNN 的 VAD 功能验证

基于 DNN 的 VAD 功能验证包括模型验证和硬件验证。在模型验证中，本节针对提出的多阶量化共享乘法器与标准乘法器实现的 VAD 系统在不同噪声类型不同信噪比下的精确度作分析比较；在硬件验证中，利用 EDA 工具对多阶量化共享乘法器、MFCC 以及基于 DNN 的 VAD 系统进行功能验证和评估。

5.1.1 验证环境

基于 DNN 的高鲁棒性低功耗 VAD 系统的验证步骤被分为两步：1) 模型验证；2) 寄存器传输级 (Register Transfer Level, RTL) 验证。本章在验证 VAD 模型过程中，主要用到了 3 个验证平台，分别是 AxBench^[53]、TensorFlow^[54]以及 Kaldi。其中 AxBench 用于特征提取过程中将 FFT 和 DCT 用神经网络的方法代替实现，只需要在平台移植 FFT、DCT 的源代码，生成的精确的输入输出数据用作训练数据集和测试数据集，通过设置网络参数，最后在允许的精确范围内生成最佳拓扑结构；TensorFlow 和 Kaldi 用于 VAD 模型的整体验证，分别针对不同的数据集，通过不停地优化 VAD 模型，验证采用不同噪声比、不同位宽以及多阶量化近似乘法时所对应的不同精确度。

本章采用 Verilog HDL 硬件描述语言实现整个 VAD 加速器系统，采用 Synopsys 公司的 VCS (Verilog Compiler Simulator) 工具和 Xilinx 的 Virtex-7 XC7VX690T FPGA 工具做功能仿真和验证，采用 Synopsys 公司的 DC (Design Compiler) 工具做综合。本文使用 TSMC28nm 工艺，VAD 加速器的原型系统使用多项目晶圆 (Multi Project Wafers, MPW) 服务进行流片。

5.1.2 验证结果及分析

1) 模型验证

第四章基于 DNN 的高鲁棒性低功耗 VAD 加速器的硬件设计提出了优化方案，设计并实现了 VAD 加速器的动态精度可配运算，将多阶量化共享乘法器引入到 VAD 模型中，通过设置精确度阈

值参数，选择不同噪声环境下的不同精确度要求的量化阶数。本文首先对多阶量化共享乘法器和标准乘法器在 VAD 加速器应用中的不同信噪比（即 SNR=-5/0/5dB）下的 AUC 值（Area Under Curve, AUC）和功耗进行对比。AUC 为受试者工作特征曲线（Receiver Operating Characteristic curve, ROC 曲线）下方的面积大小。又由于 ROC 曲线一般都处于 $y=x$ 这条直线的上方，所以 AUC 的取值范围在 0.5 和 1 之间。对应 AUC 更大的分类器效果更好。本文使用 Aurora 和 Wall Street 分别作为训练数据库和测试数据库，数据库中超过 70% 的帧是语音，通过 AUC 值可以衡量 VAD 系统的漏判率和误判率，因此检测 AUC 参数比直接检测精度更能精准评估整个 VAD 系统的精确性。

表 5-1 共享乘法器和标准乘法器在 VAD 加速器应用中的不同信噪比下的 AUC 和功耗参数对比

multiplier-order	Noise type	SNR(dB)	AUC(%)	Power(μ W)
standard	Babble	-5	83.21	50
		0	90.11	
		5	93.12	
	Car	-5	93.40	
		0	96.33	
		5	97.20	
8	Babble	-5	83.21	12
		0	90.11	
		5	93.12	
	Car	-5	93.40	
		0	96.33	
		5	97.20	
4	Babble	-5	79.88	11
		0	86.51	
		5	89.40	
	Car	-5	89.66	
		0	92.48	
		5	93.31	
2	Babble	-5	78.22	9
		0	84.70	
		5	87.53	
	Car	-5	87.80	
		0	90.55	
		5	91.37	
1	Babble	-5	62.41	6
		0	67.58	
		5	69.84	
	Car	-5	70.05	
		0	72.25	
		5	72.90	

表 5-1 所示,要对比的对象基于不同乘法器的 VAD 加速器。其中乘法器包括标准乘法器和 8 阶、4 阶、2 阶以及 1 阶量化的共享乘法器,使用的噪声类型为两种,分别为 Babble、Car,在同一种噪声类型下设置三种 SNR 环境,分别为 -5dB、0dB、5dB,要对比的参数分别是 AUC 值和功耗大小。从表中可以明显看出:在 VAD 加速器的精确度方面,不管使用标准乘法器还是多阶量化共享乘法器,随着信噪比的增强,精确度随之提高,并且 Car 噪声类型下的分类精确度比 Babble 高,8 阶量化的共享乘法器在 VAD 模型中的精确度和标准乘法器的精确度同样高,即没有精度损失,在 Car 噪声类型下 5dB 信噪比环境中 AUC 值约高达 97.2%,但是随着共享乘法器的量化阶数的减少,VAD 系统的 AUC 值也在下降,一阶量化下的共享乘法器在 Car 噪声类型下 5dB 信噪比环境中的 AUC 值约 72.9%;在功耗消耗方面,标准的乘法器应用在 VAD 系统中的系统功耗为 $50\mu\text{W}$,而使用 8 阶量化共享乘法器是的 VAD 系统功耗为 $12\mu\text{W}$,使用 1 阶量化共享乘法器是的系统功耗为 $6\mu\text{W}$,约是使用标准乘法器时的 1/8。显然,使用共享乘法器不但可以明显的降低基于 DNN 的高鲁棒性低功耗 VAD 系统的功耗,并且保证精确度也在可接受范围内。因此,可以根据不同的噪声环境要求选择合适的量化阶数的共享乘法器。

图 5-1 的柱状图更直观的展示了本文的实验结果。随着信噪比的增强,VAD 的精确度随之提高。共享乘法器的量化阶数减少,虽然电路功耗降低但是 AUC 值随之下降。在 SNR=0 的 Car 噪声环境下,使用一阶量化的共享器的 VAD 相对于使用标准乘法器的 VAD,其精确度下降了 24%。因此当在精确度要求高的前提条件下,使用高量化阶数的共享乘法器,而在低精确度要求下,使用低量化阶数的共享乘法器,使得 VAD 系统的精确度达到要求的同时其系统功耗和面积达到最低。




图 5-1 多阶量化共享乘法器和标准乘法器在 VAD 加速器应用中在不同信噪比下的 AUC 对比柱状图

2) RTL 级仿真验证

图 5-2、5-3、5-4 以及 5-5 是前文中设计的基于多阶量化的共享乘法器的 RTL 实现仿真波形。由波形图可以看出,八阶量化的共享乘法器的乘法结果均为精确结果,而四阶量化共享乘法器由于只有四个子计算单元故精确度有所下降,二阶量化共享乘法器由于只有两个子计算单元故精确度下降

地更明显，一阶量化共享乘法器取消了共享乘法阵列，当计算大数据时精确度大度下降。结合上文对乘法器功耗的比较表明，高阶量化共享乘法器适合精确度要求高的语音识别应用，低阶量化共享乘法器适合精确度要求低的语音识别应用。实验显示，本文设计的多阶量化共享乘法器达到设计目标。




图 5-2 八阶量化共享数乘法器的功能实现




图 5-3 四阶量化共享数乘法器的功能实现




图 5-4 二阶量化共享数乘法器的功能实现




图 5-5 一阶量化共享数乘法器的功能实现

图 5-6 所示为 MFCC 中的三角滤波器的滤波系数。图 5-7 位语音信号经过 MFCC 的特征提取之后得到的 26 维特征向量。图 5-8 是基于 DNN 的高鲁棒性低功耗 VAD 加速器功能实现，仿真波形中给出了权值的更新过程和输入数据的加载过程。计算的结果通过并行输出的方法一次性输出，输出数据线为 DATA_OUT，这一信号线通过 FINISH_OUT 信号与系统进行握手，当该信号有效时，系统开始接收输出数据。




图 5-6 梅尔滤波系数




图 5-7 26 维 MFCC 特征向量




图 5-8 基于 DNN 的高鲁棒性低功耗 VAD 系统功能实现

5.2 基于 DNN 的 VAD 版图测试结果

图 5-9 所示的右下角为 VAD 加速器顶层版图设计。VAD 加速器的原型系统由以下部分组成：VAD 加速器宏；四个 SRAM 模块，包括系统存储器、配置存储器、权重存储器以及数据存储器；以及一些其他的控制模块。本文使用 TSMC28nm 工艺，VAD 加速器的原型系统使用多项目晶圆（Multi Project Wafers, MPW）服务进行流片。不包括存储面积在内，VAD 加速器宏的面积为 $0.4 \times 0.7 \text{mm}^2$ ，整个 VAD 加速器的系统面积为 0.52mm^2 。片上存储的工作电压为 0.8V，位线电压降为 430mV，摆幅为 0.8V 至 0.37V。VAD 加速器和其他模块的逻辑电源电压为 0.58V，工作频率为 1.6MHz。本章使用 Synopsys HSI 在 25°C TT 工艺转角条件下进行时序和功耗评估。




图 5-9 VAD 加速器顶层版图设计

图 5-10 为不同量化阶数的共享乘法器和传统的乘法器在 VAD 加速器应用中的系统功耗对比，从柱状图中可以明显看出，利用 8 阶量化的共享乘法器代替传统的乘法器实现的 VAD 加速器系统，系统功耗相比于传统的 VAD 加速器减少了 76%，而 1 阶量化的共享乘法器实现的 VAD 加速器系统，相比于传统的 VAD 加速器系统功耗下降了 88%。实验结果显示，利用多阶量化共享乘法器实现的




图 5-10 多阶量化共享乘法器和标准乘法器在 VAD 加速器应用中的系统功耗对比柱状图

表 5-2 为标准乘法器、对数乘法器以及共享乘法器的性能参数。对数乘法器的工作主频是传统乘法器的两倍，计算延时小，但是功耗大，面积也大；与标准乘法器相比，共享乘法器的主频相同，功耗降低为 10%，面积减小至 12%，面积约是对数乘法器的 4%。本文设计的基于 DNN 的高鲁棒性低功耗 VAD 的工作主频为 1.6MHz，综合后实验结果显示，共享乘法器的功耗仅为 0.2 μ W。从表中的实验数据可知，使用共享乘法器可以大幅降低 VAD 系统的功耗和面积。

表 5-2 乘法器的性能参数对比

乘法器类型	主频 (M)	功耗(μ W)	面积(mm^2)
标准乘法器	500	690	0.0025
对数乘法器	1000	830	0.0069
共享乘法器	500	69	0.0003
本文	1.6	0.2	0.0003

表 5-3 列出了基于 DNN 的高鲁棒性低功耗 VAD 加速器的具体面积和功耗。

表 5-3 VAD 加速器的能量和功耗占比

模块	功耗分布		面积分布	
	功耗(μ W)	占比(%)	面积(μm^2)	占比(%)
阵列	2.59	42.88	2135823	42.33
存储	2.22	36.75	2407823	47.73
其它	1.23	20.36	500915	9.92
全部	6.04	100	5044561	100

5.3 与典型 VAD 的比较分析

表 5-4 将本文提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器与目前最先进的基于 DNN 的 VAD 加速器^[71]和最先进的 DNN 加速器^[72]作比较。从表中的实验结果可以得出，工作 Price^[71]和本文提出的 VAD 加速器系统中的 DNN 加速器架构都是全连接(Full Connect, FC)，而在 Thinker^[72]提出的 DNN 加速器不仅在可以工作在 FC 层而且可以处理其他层（例如，卷积层等）。本文采用基于多阶量化的共享乘法器和延时链实现的数模混合近似计算，而 Price^[71]和 Thinker^[72]的实现均采用标准乘法器。本文提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器的能效约为 33.33~66.67TOPS/W，12dB 下的精确度为 96%。

表 5-4 本文提出的基于 DNN 的 VAD 加速器与目前先进的 VAD 加速器以及 DNN 加速器比较

平台	Price ^[71]	Thinker ^[72]	本文
DNN 架构	FC	FC/Others	FC
工艺	65nm	65nm	28nm
主频	10.2~86.8MHz	10MHz	1.6MHz
数据位宽	16	8/16	8
权重位宽	16	8/16	8
计算方式	精确计算		近似计算
功耗峰值	22.3 μ W	4mW	6~12 μ W
面积	476K gates	—	0.52mm ²
吞吐率	—	20.4 GOPS	0.4 GOPS
能效	—	5.09TOPS/W	33.33~66.67TOPS/W
精确度@12dB	87%	—	72%~96%

与当前主流的 DNN 加速器 Thinker^[72]相比，本文提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器可以实现更高的能效，其能效是 Thinker^[72]的 6.5 倍以上。与 Thinker 相比，本文提出的 VAD 加速器不仅提高了网络压缩的等效吞吐率，而且采用的近似计算方案也大幅提高了计算能效，这使得本文提出的加速器在八阶量化条件下能效为 Thinker 的 6.5 倍以上。与采用了宽电压技术的 Price^[71]相比，本文提出的 DNN 加速器在八阶量化条件下的精确度提高了 9%。

最后，本章将基于 DNN 的高鲁棒性低功耗 VAD 加速器的最终实现的指标与预期的设计指标做了对比，对比结果如表 5-5 所示。设计采用了原定方案中 DNN 架构、工艺和数据位宽，由于采用了多阶量化共享乘法器，VAD 加速器的功耗为 6~12 μ W，当使用一阶量化的共享乘法器时 VAD 的功耗为 6 μ W，当使用八阶量化的共享乘法器时 VAD 加速器的能效达到预期的 2.2 倍，芯片实际面积和预

期面积相当。实验结果证明本文实现的 VAD 加速器达到预期设计指标。

表 5-5 实际实现指标与设计指标对比

	设计指标	实际指标
DNN 架构	FC	
工艺 (nm)	28	28
主频 (MHz)	1.6	1.6
数据位宽 (bits)	8	8
功耗 (μW)	<10	6~12
能效 (TOPS/W)	>30	33.33~66.67
面积 (mm^2)	<0.6	0.52
精确度@12dB (%)	>90	96

5.4 本章小结

第五章首先介绍了本文的实验环境，包括模型验证以及 RTL 级验证环境，并对最后的验证结果进行比较分析。本章首先将提出的多阶量化共享乘法器与标准乘法器实现的 VAD 系统在不同噪声类型不同信噪比下的精确度作分析比较；其次，针对本文提出的基于混合精度近似计算的高能效 DNN 加速器，本章使用 EDA 工具验证多阶量化共享乘法器、MFCC 以及基于数模混合近似计算实现的 VAD 系统的功能和各项性能指标；最后，本章将提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器的性能指标与近几年主流的 VAD 加速器和 DNN 加速器作对比。实验结果显示，相比于标准的乘法器实现的 VAD 加速器，基于多阶量化共享乘法器实现的 VAD 加速器可以极大的降低系统功耗，并且保证 AUC 值在允许的范围内。相比于标准的乘法器，基于一阶量化的共享乘法器实现的 VAD 加速器，AUC 值下降了约 24.3%，但是功耗下降为原来的 12%。因此针对精确度要求低的环境可以使用一阶量化共享乘法器降低系统功耗。同时，和目前最先进的基于 DNN 的 VAD 加速器以及 DNN 加速器架构相比，本文提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器的精确度相比于为 Price^[71]的增加了 9%，能效约为 Thinker^[72]的 6.5 倍。

第六章 总结与展望

6.1 总结

语音作为最自然便捷的交流方式，一直是人机通信和交互最重要的研究领域之一。近年来，越来越多的语音识别智能应用走入了大家的日常生活，苹果的 Siri、微软的小娜、科大讯飞的语音输入法等都是其中的典型代表。VAD 作为语音识别领域中必不可少的关键技术之一，这个模块的精度性和功耗在整个语音识别系统中起着十分重要的作用。随着神经网络的快速发展与广泛应用，将神经网络的算法应用到 VAD 中势必成为一个新的研究热点。本文的研究内容主要有以下几点：

第一章为绪论，首先介绍了课题背景和研究意义；其次阐述了 VAD 在国内外的研究现状，并指出了 VAD 加速器的设计难点；最后说明了本文的研究内容和设计指标。第二章首先将目前主流的特征提取算法作对比分析，优化基于 MFCC 的特征提取算法，接着将目前主流的语音分类算法作分析比较，最后提出基于 DNN 的语音分类方法，最后为了降低 VAD 系统的功耗，基于 DNN 网络的良好容错能力，提出在 DNN 计算单元中引用近似乘法。第三章立足于第二章的算法分析和提出的方案，基于优化后的特征提取算法和语音分类算法设计了 VAD 的硬件结构。第四章阐述了基于 DNN 的高鲁棒性低功耗 VAD 系统架构优化，以及 DNN 加速器的映射方案，在 DNN 加速器中引入数模混合近似计算，基于多阶量化的共享乘法器实现 VAD 加速器的动态精度可配运算。第五章对本文提出的基于 DNN 高鲁棒性低功耗 VAD 的实验结果进行分析，对 VAD 做功能验证和综合结果分析，并将提出的 VAD 系统与近几年最先进的 DNN 加速器和最先进的 VAD 系统作对比。第六章对本文的工作做了总结和展望。

本文提出的基于 DNN 的高鲁棒性低功耗 VAD 加速器，其中的 DNN 加速器采用数字模拟混合近似计算单元降低 VAD 系统的功耗。本文采用 TSMC28nm HPC + 工艺，VAD 加速器的系统面积为 0.52mm^2 ，片上存储的工作电压为 0.8V，VAD 加速器和其他模块的逻辑电源电压为 0.58V，工作频率为 1.6MHz。本文使用 Synopsys HSPICE 在 25°C TT 工艺转角条件下进行时序和功耗评估。VAD 的系统功耗为 $6\sim 12\mu\text{W}$ ，约为 Price^[71]的 27%，能效达到 $33.33\sim 66.67\text{TOPS/W}$ ，约为 Thinker^[72]的 6.5 倍。

6.2 展望

本文基于数模混合近似计算提出了一种基于 DNN 的高鲁棒性低功耗 VAD 设计，通过优化特征提取和语音分类算法，利用 DNN 代替实现 FFT、DCT 以及语音分类，并且在 DNN 中引入延时链作为计算单元的累加单元和多阶量化近似乘法器作为计算单元的乘法单元，实现 VAD 加速器的动态精度可配运算。本文提出的 VAD 系统在性能、功耗、面积的优化方面均取得了优良的效果，然而还有

很多工作需要进一步完善:

1) VAD 的算法核心流程是特征提取和语音分类, 本文分别用 MFCC 的算法和 DNN 的算法实现。虽然相对比传统的算法流程, 本文做了很大的优化, 但是由于时间关系, 本文没有尝试用 DNN 的算法直接实现 VAD 的特征提取算法和语音分类算法。VAD 系统的电路复杂度, 计算延时等参数还可以进一步优化。

2) 针对本文提出的近似计算单元设计, 本文设计了一种多阶量化共享乘法器, 将乘法器的并行计算, 吞吐率高, 功耗低等计算优势与神经网络紧密结合, 但是目前有一些使用了模拟方法进行近似计算的方案也值得深入研究, 故在后续的研究工作中, 会考虑将这一类近似计算方法引入到本文的工作中。另外, 最前沿的神经网络提出了网络二值化的概念, 本文没有引用二值的方法, 因此在后续的工作中也会将此列入研究点。

致谢

时光荏苒，光阴如梭，硕士入学那天的情景还历历在目。这三年的研究生生涯，不管是学习还是生活，都让我学习了很多。3年的研究生生涯即将结束，在东大度过的这几年，让我成长了许多，无论是学业、科研、还是生活上都受益匪浅。东大“止于至善”的校训无时无刻不提醒着我，在即将走出校园之际，更加希望将这一东大人的信仰贯彻到以后的工作和生活中，追求卓越。在此，谨向所有给与我帮助的老师、同学、亲人们致以真挚的感谢，是他们成就了现在的我。

首先，我要感谢我的导师杨军教授，他的科研高度和治学态度深深的影响着我，让我从更高、更广的角度去思考我遇到的问题，往往可以达到意想不到的效果。是他给了我很多交流学习的机会，让我可以接触更多的人，学习更多的知识。

接着，我要特别感谢我的指导老师刘波老师。在我的研究生生涯中，从平时的科研工作到开题、论文的框架、成果的验收等等每个关键的转折点，刘波老师都给予了我强有力的支持和帮助，耐心的辅导我，为我指点迷津。在他的指导下，我才能在攻读研究生期间发表多篇论文及专利，取得现在的研究成果。他渊博的学识，严谨的态度让我进一步认识到自己的不足，驱使着我朝着刘老师这样的榜样前行。

此外，还要感谢实验室的龚宇博士，在学术方面给了我很多中肯的建议，在生活方面也不时地给与我帮助，减轻了我很多情绪上的压力。感谢已经毕业了的王晓彤师姐，季程、汪冬明、葛伟琪师兄。尤其感谢实验室的同学孙锰阳、范虎、于华振对我的生活学术上的帮助。感谢实验室的阮星、陈壮、朱智洋师兄对我工作的支持。

最后感谢我的家人，他们一直辛苦的工作，支持着我的学业，操心我的学业的同时还要担心我的身体健康。在我在情绪低落时有人倾听，在我快乐时有人分享。谢谢你们，未来的路上我会一步一个脚印，坚持不懈，带着你们的鼓励勇往直前。

参考文献

- [1] M. Price, J. Glass, A. P. Chandrakasan. A 6 mW, 5,000-word real-time speech recognizer using WFST models[J]. IEEE Journal of Solid-State Circuits, 2014, 50(1): 102-112
- [2] He G, Sugahara T, Izumi S, et al. A 40-NM 54-MW 3×-real-time VLSI processor for 60-kWord continuous speech recognition[C]. In Custom Integrated Circuits Conference (CICC). Taipei City: IEEE, 2012. 222-234
- [3] J A Haigh, J S Mason. Robust voice activity detection using cepstral features[J]. IEEE TENCON, 1993, (3): 321–324
- [4] N B Yoma, F McInnes, M Jack. Robust speech pulse-detection using adaptive noise modeling[J]. Electronics Letters, 1996, 32(15): 1350-1352
- [5] Inc G. Convolutional, long short-term memory, fully connected deep neural networks[C]. In 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Brisbane: IEEE, 2015. 782-793
- [6] Ji C P , Gao M , Yang J . Voice Activity Detection Based on Multiple Statistical Models[J]. Advanced Materials Research, 2011, 181(2):765-769.
- [7] Hinton G, Deng L, Yu D, et al. Deep Neural Networks for Acoustic Modeling in Speech Recognition: The Shared Views of Four Research Groups[J]. IEEE Signal Processing Magazine, 2012, 29(6):82-97
- [8] Marchi E, Ferroni G, Eyben F, et al. Multi-resolution linear prediction based features for audio onset detection with bidirectional LSTM neural networks[J]. ICASSP, 2014, 24(1): 2164-2168
- [9] Brutti A, Ravanelli M, Svaizer P, et al. A speech event detection and localization task for multiroom environments[C]. In 2014 4th Joint Workshop on Hands-free Speech Communication and Microphone Arrays (HSCMA). Villers-les-Nancy: IEEE, 2014. 421-431
- [10] Fitch F B. McCulloch Warren S. and Pitts Walter. A logical calculus of the ideas immanent in nervous activity[J]. Journal of Symbolic Logic, 1944, 9(2): 49-50
- [11] Hebbdo. The Organization of Behavior [M]. New York: Wiley, 1949
- [12] Rosenblatt F. The perception: A probabilistic model for information storage and organization in the brain[J]. Psychological Review, 1958, 65(6): 386-408
- [13] Hughes T, Mierle K, Inc G. RECURRENT NEURAL NETWORKS FOR VOICE ACTIVITY DETECTION[C]. In 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. Vancouver: IEEE, 2013. 71-79
- [14] Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Networks[J]. Science, 2006, 313(5786):504-507
- [15] Achanta S, Chennupati N, Pannala V, et al. Voice Activity Detection using Temporal Characteristics of Autocorrelation Lag and Maximum Spectral Amplitude in Sub-bands[C]. In 2018 10th International Conference on Electrical and Computer Engineering (ICECE). Dhaka: IEEE, 2016. 297-300

- [16] Hwang Y, Jeong M H, Oh S R, et al. Applying the Bi-level HMM for Robust Voice-activity Detection[J]. Journal of Electrical Engineering & Technology, 2017, 12(1): 373-377
- [17] Mayorga P, Chavez G, Druzgalski C, et al. Lung sounds focused events classification and segmentation with VAD-GMM[C]. In 2017 Global Medical Engineering Physics Exchanges/Pan American Health Care Exchanges (GMEPE/PAHCE). Tuxtla Gutierrez: IEEE, 2017. 290-297
- [18] Kinnunen T, Chernenko E, Tuononen M, et al. Voice Activity Detection Using MFCC Features and Support Vector Machine[C]. 2016 International Conference on Robotics, Automation and Sciences (ICORAS). Ayer Keroh:IEEE, 2016. 1-5
- [19] Markoff J. How many computers to identify a cat? [N]. The New York Times, 2012-06-25
- [20] Markoff J. Scientists see promise in deep-learning programs [N]. The New York Times, 2012-11-23
- [21] Socher R, Lin C Y, Ng A Y, et al. Parsing Natural Scenes and Natural Language with Recursive Neural Networks[J]. International Conference on Machine Learning, 2011, 50(1): 129-136
- [22] 10 Breakthrough Technologies 2013[N]. MIT Technology Review, 2013-04-23
- [23] Dahl G E, Yu D, Deng L, et al. Context-Dependent Pre-trained Deep Neural Networks for Large Vocabulary Speech Recognition[J]. IEEE Transactions on Audio Speech & Language Processing, 2012, 20(1):30-42
- [24] NAIR V, HINTON G E. 3D object recognition with deep belief nets[J]. International Conference on Neural Information Processing Systems, 2009, 18(7): 1339-1347
- [25] CHO K, van MERRIENBOER B, GULCEHRE C, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J]. Computer Science, 2014, 22(2): 21-26
- [26] BAHDANAU D, CHO K, BENGIO Y. Neural Machine Translation by Jointly Learning to Align and Translate[J]. Computer Science, 2014, 14(2): 31-38
- [27] Eyben F, Weninger F, Squartini S, et al. Real-Life Voice Activity Detection with LSTM Recurrent Neural Networks and application to Holliwood Movies[C]. In 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. Vancouver: IEEE, 2013. 20-28
- [28] Tachioka Y, Narita T, Watanabe S, et al. Ensemble integration of calibrated speaker localization and statistical speech detection in domestic environments[C]. In 2014 4th Joint Workshop on Hands-free Speech Communication and Microphone Arrays (HSCMA). Villers-les-Nancy: IEEE, 2014. 27-38
- [29] Ferroni G, Bonfigli R, Principi E, et al. A Deep Neural Network Approach for Voice Activity Detection in Multi-Room Domestic Scenarios[C]. In 2015 International Joint Conference on Neural Networks (IJCNN). Killarney : IEEE, 2015. 1-10
- [30] Gupta P K , Jangi S , Lamkin A B , et al. Voice activity detector for speech signals in variable background noise[J]. Journal of the Acoustical Society of America, 1997, 103(2):28.
- [31] G E Dahl, D Yu, L Deng, et al. Context-dependent pretrained deep neural networks for large-vocabulary speech recognition[J]. IEEE, 2012, 20(1): 30-42
- [32] E. Nemer, R. Goubran, S. Mahmoud. Robust voice activity detection using higher-order statistics in the LPC residual domain[J]. IEEE Transactions on Speech & Audio Processing, 2001, 9(3): 217–231

- [33] I V McLoughlin. The use of low-frequency ultrasound for voice activity detection[J]. Proc Interspeech, 2014, 20(3): 1553–1557
- [34] G Aneja, B Yegnanarayana. Single frequency filtering approach for discriminating speech and nonspeech[J]. IEEE-ACM Transactions on Audio Speech and Language Processing, 2015, 23(4): 705–717
- [35] J. Sohn, N. S. Kim, W. Sung. A statistical model-based voice activity detection[J]. IEEE Signal Process Lett, 1999, 6(1): 1–3
- [36] D Ying, Y Yan, J Dang, et al. Voice activity detection based on an unsupervised learning framework[J]. IEEE Transactions on Audio & Speech & Language Processing, 2011, 19(8): 2624–2644
- [37] S Gazor, W Zhang. A soft voice activity detector based on a Laplacian-Gaussian model[J]. IEEE Transactions on Speech and Audio Process, 2003, 11(5): 498–505
- [38] Badami K M H, Lauwereins S, Meert W, et al. A 90 nm CMOS, Power-Proportional Acoustic Sensing Frontend for Voice Activity Detection[J]. Solid-State Circuits, IEEE Journal of, 2016, 51(1): 291–302
- [39] Hashemi S A, Condo C, Ercan F, et al. Memory-Efficient Polar Decoders[J]. IEEE Journal on Emerging and Selected Topics in Circuits and Systems, 2017, 7(4): 604–615
- [40] J Ramírez, J C Segura, C Benítez, et al. Statistical voice activity detection using a multiple observation likelihood ratio test[J]. IEEE Signal Processing Letters, 2005, 12(10): 689–692
- [41] S O Sadjadi, J H L Hansen. Unsupervised speech activity detection using voicing measures and perceptual spectral flux[J]. IEEE Signal Processing Letters, 2013, 20(3): 197–200
- [42] P Teng, Y Jia. Voice activity detection via noise reducing using non-negative sparse coding[J]. IEEE Signal Processing Letters, 2013, 20(5): 475–478
- [43] S Mousazadeh, I Cohen. Voice activity detection in presence of transient noise using spectral clustering[J]. IEEE Transactions on Audio & Speech & Language Processing, 2013, 21(6): 1261–1271
- [44] J Gorriz, J Ramirez, E Lang, et al. Hard c-means clustering for voice activity detection[J]. Speech Communication, 2005, 48(12): 1638–1649
- [45] XL Zhang, J Wu. Deep belief networks based voice activity detection[J]. IEEE Transactions on Audio & Speech & Language Processing, 2013, 21(4): 697–710
- [46] T Hughes, K Mierle. Recurrent neural networks for voice activity detection[C]. In IEEE International Conference on Acoustics. Taipei City:IEEE, 2013. 7378–7382
- [47] F Eyben, F Weninger, S Squartini, et al. Real-life voice activity detection with lstm recurrent neural networks and an application to Hollywood movies[C]. In 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. Vancouver: IEEE, 2013. 483–487
- [48] G Saon, S Thomas, H Soltau, S Ganapathy, et al. The IBM speech activity detection system for the DARPA RATS program[C]. In 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Brisbane: IEEE, 2013. 3497–3501
- [49] XL Zhang, D L Wang. Boosted contextual information for deep neural network based voice activity detection[J]. IEEE-ACM Transactions on Audio Speech and Language Processing, 2016, 24(2):

1534–1538

- [50] S Thomas, G Saon, M Van Segbroeck, et al. Improvements to the IBM speech activity detection system for the DARPA RATS program[J]. IEEE International Conference on Acoustics, 2015, 10(2): 4500–4504
- [51] XL Zhang. Unsupervised domain adaptation for deep neural network based voice activity detection[J]. IEEE ICASSP, 2014, 35(2): 6864–6868
- [52] K Walker, S Strassel. The RATS radio traffic collection system[J]. ISCA Odyssey, 2012, 11(1): 291–297
- [53] Yazdanbakhsh A, Mahajan D, Lotfi-Kamran P, et al. AXBENCH: A Multi-Platform Benchmark Suite for Approximate Computing[J]. IEEE Design & Test, 2016, 34(2): 60-68
- [54] Ram??Rez J , José C Segura, Ben??Tez C , et al. Efficient voice activity detection algorithms using long-term speech information[J]. Speech Communication, 2004, 42(3-4):271-287
- [55] Walsh C A. Peter Huttenlocher (1931-2013) [J]. Nature, 2013, 502(7470): 172
- [56] Sadjadi S O, Hansen J H L. Unsupervised Speech Activity Detection Using Voicing Measures and Perceptual Spectral Flux[J]. IEEE Signal Processing Letters, 2013, 20(3): 197-200
- [57] Babić Z, Avramović A, Bulić P. An iterative logarithmic multiplier[J]. Microprocessors & Microsystems, 2011, 35(1): 23-33
- [58] Garofalo V, Petra N, De Caro D, et al. Low error truncated multipliers for DSP applications[C]. In IEEE International Conference on Electronics, Circuits and Systems. Brisbane: IEEE, 2008. 29-32
- [59] H Wang, Y Xu, M Li. Study on the MFCC similarity-based voice activity detection algorithm, Int Conf on Artificial Intelligence[C]. In Management Science and Electronic Commerce(AIMSEC), Deng Leng: IEEE, 2011. 4391-4394
- [60] Hughes T, Mierle K, Inc G. RECURRENT NEURAL NETWORKS FOR VOICE ACTIVITY DETECTION[C]. In IEEE International Conference on Acoustics. Vancouver: IEEE. 2013. 7378-7383
- [61] Silva D A, José Augusto Stuchi, Violato R P V, et al. Exploring Convolutional Neural Networks for Voice Activity Detection[J]. Cognitive Technologies, 2017, 8(1): 37-47
- [62] Kang T G, Lee K H, Kang W H, et al. DNN-based voice activity detection with local feature shift technique[C]. In Signal & Information Processing Association Summit & Conference. Jeju: IEEE, 2017. 19-28
- [63] Rais M H. Efficient hardware realization of truncated multipliers using FPGA[J]. International Journal of Applied Science Engineering & Technolo, 2009, 3(9): 1740-1744
- [64] Van L D, Lee S H. A generalized methodology for lower-error area-efficient fixed-width multipliers[J]. IEEE Transactions on Circuits & Systems I Regular Papers, 2005, 52(8): 1608-1619
- [65] Chen Y H, Krishna T, Emer J, et al. 14.5 Eyeriss: An energy-efficient reconfigurable accelerator for deep convolutional neural networks[J]. IEEE Journal of Solid-State Circuits, 2017, 52(1): 127-138
- [66] Babić Z, Avramović A, Bulić P. An iterative logarithmic multiplier[J]. Microprocessors & Microsystems, 2011, 35(1): 23-33

- [67] McLaren D J. Improved Mitchell-based logarithmic multiplier for low-power DSP applications[C]. In: Soc Conference. IEEE International[System-on-chip]. Portland: IEEE, 2003. 53-56
- [68] Kong M Y, Langlois J M P, Al-Khalili D. Efficient FPGA implementation of complex multipliers using the logarithmic number system[C]. In IEEE International Symposium on Circuits and Systems(ISCAS). Seattle: IEEE, 2008. 3154-3157
- [69] Mahalingam V, Ranganathan N. Improving Accuracy in Mitchell's Logarithmic Multiplication Using Operand Decomposition[J]. IEEE Transactions on Computers, 2006, 55(12): 1523-1535
- [70] Shah M, Wang J, Blaauw D, et al. A fixed-point neural network for keyword detection on resource constrained hardware[C]. In 2015 IEEE Workshop on Signal Processing Systems (SiPS). Hangzhou: IEEE, 2015. 31-39
- [71] Price, Michael, J Glass, et al. A Low-Power Speech Recognizer and Voice Activity Detector Using Deep Neural Networks[J]. IEEE Journal of Solid-State Circuits, 2017, 53(1): 66-75
- [72] Yin, Shouyi, Tang, et al. A High Energy Efficient Reconfigurable Hybrid Neural Network Processor for Deep Learning Applications[J]. IEEE Journal of Solid-State Circuits, 2017, 53(4): 968-982
- [73] Hennessy J L, Patterson D A. Computer Architecture: A Quantitative Approach[M]. USA: Morgan Kaufmann, 2007. 288-315

攻读硕士学位期间发表的论文

● 攻读硕士学位期间发表的论文

- [1] Wang Zhen, **Xia Mengwen**, Liu Bo, Ruan Xing, Gong Yu, Yang Jinjiang, Ge Wei and Yang Jun. EERA-DNN: An energy-efficient reconfigurable architecture for DNNs with hybrid bit-width and logarithmic multiplier. IEICE Electronics Express, vol. 15, no. 8, 2018.
- [2] Liu Bo, Ruan Xing, **Xia Mengwen**, Gong Yu, Yang Jinjiang, Ge Wei and Yang Jun. An Energy-Efficient Accelerator for Hybrid Bit-width DNNs, IEEE Symposium Series on Computational Intelligence, pp. 1-8, Honolulu, HI, United states, February 2, 2018
- [3] Liu Bo, Qin Hai, Gong Yu, Ge Wei, **Xia Mengwen** and Shi Longxing. EERA-ASR: An Energy-Efficient Reconfigurable Architecture for Automatic Speech Recognition with Hybrid DNN and Approximate Computing, IEEE Access, vol. 6, 2018.
- [4] **夏梦雯**, 刘波. 基于 DNN 的高鲁棒性低功耗 VAD 加速器设计. 东南大学校庆论文, 2018

● 攻读硕士学位期间发表的专利

- [1] 刘波, **夏梦雯**, 秦海, 于华振, 范虎, 杨军. 一种适用于神经网络的乘加计算方法和计算电路. 申请号: 201810894109.2
- [2] 刘波, **夏梦雯**, 郭世晟, 杨晶, 龚宇, 杨军. 面向深度神经网络加速器应用的近似计算系统. 申请号: 201810409591.6
- [3] 刘波, 郑梦瑶, **夏梦雯**, 龚宇, 杨军, 时龙兴. 基于动态精度可配运算的近似计算可重构阵列. 申请号: 201710882550.4